

DIEGO ARMENTEROS RIAZA

Memoria TFG.pdf

-  Turnitin Memoria Final
-  TFG ETSIINF (Moodle PP)
-  Universidad Politecnica de Madrid

Detalles del documento

Identificador de la entrega

trn:oid:::1:3607599227

Fecha de entrega

7 jul 2026, 12:18 p.m. GMT+2

Fecha de descarga

7 jul 2026, 12:57 p.m. GMT+2

Nombre del archivo

19871_DIEGO_ARMENTEROS_RIAZA_Memoria_TFG_77439_559636610.pdf

Tamaño del archivo

1002.9 KB

61 páginas

18.526 palabras

101.015 caracteres

17% Similitud general

El total combinado de todas las coincidencias, incluidas las fuentes superpuestas, para ca...

Filtrado desde el informe

- Texto citado

Fuentes principales

- 13%  Fuentes de Internet
 - 7%  Publicaciones
 - 9%  Trabajos entregados (trabajos del estudiante)
-

Fuentes principales

- 13% Fuentes de Internet
- 7% Publicaciones
- 9% Trabajos entregados (trabajos del estudiante)

Fuentes principales

Las fuentes con el mayor número de coincidencias dentro de la entrega. Las fuentes superpuestas no se mostrarán.

1	Trabajos del estudiante	Universitat Oberta de Catalunya	3%
2	Internet	oa.upm.es	1%
3	Publicación	García Ordoñez, Jasirys Mariel. "Estudio de viabilidad de uso del TLD-100 como do..."	1%
4	Trabajos del estudiante	Universidad Politécnica de Madrid	<1%
5	Internet	hdl.handle.net	<1%
6	Internet	roderic.uv.es	<1%
7	Trabajos del estudiante	Universidad Carlos III de Madrid - EUR	<1%
8	Internet	repositorio.uam.es	<1%
9	Internet	www.coursehero.com	<1%
10	Trabajos del estudiante	Universidad Internacional de la Rioja	<1%
11	Internet	www.famg.org.ar	<1%

12	Trabajos del estudiante University of York	<1%
13	Internet burjcdigital.urjc.es	<1%
14	Internet www.tdx.cat	<1%
15	Internet www.researchgate.net	<1%
16	Internet helvia.uco.es	<1%
17	Internet digibuo.uniovi.es	<1%
18	Internet www.biorxiv.org	<1%
19	Trabajos del estudiante Universidad Catolica de Avila	<1%
20	Trabajos del estudiante Uniminuto Virtual	<1%
21	Trabajos del estudiante Universidad de Valladolid	<1%
22	Trabajos del estudiante University of Auckland	<1%
23	Internet digibug.ugr.es	<1%
24	Trabajos del estudiante uncedu	<1%
25	Internet www.raem.org.ar	<1%

26	Trabajos del estudiante	UNIV DE LAS AMERICAS	<1%
27	Internet	repositorio.unap.edu.pe	<1%
28	Internet	www.ir.juit.ac.in:8080	<1%
29	Publicación	Gabriel Quiroz, Diego A. Burgos, Juan Felipe Zuluaga Molina. "Terminología del es...	<1%
30	Trabajos del estudiante	Gusto University	<1%
31	Publicación	Laura María Medina Gómez, Gonzalo Vásquez Palacio, Carlos Mario Muñetón Peñ...	<1%
32	Internet	theibfr.com	<1%
33	Internet	arxiv.org	<1%
34	Internet	eprints.whiterose.ac.uk	<1%
35	Internet	qmro.qmul.ac.uk	<1%
36	Trabajos del estudiante	Universidad Nacional de Colombia	<1%
37	Internet	researchers.mq.edu.au	<1%
38	Internet	riunet.upv.es	<1%
39	Publicación	Galnares Jimenez-Placer, Carlos. "Análisis de la deuda soberana en la UE-15", Univ...	<1%

40	Trabajos del estudiante	Universidad Autónoma de Nuevo León	<1%
41	Internet	abmir.yazd.ac.ir	<1%
42	Internet	worldwidescience.org	<1%
43	Trabajos del estudiante	Universidad Carlos III de Madrid	<1%
44	Trabajos del estudiante	Universidad Nacional de Ingeniería	<1%
45	Publicación	Zhixing Zhong, Jinglu Hu. "A Region-Aware Structured Framework Improves Predi...	<1%
46	Internet	corpus.ulaval.ca	<1%
47	Internet	sespm.es	<1%
48	Internet	zagan.unizar.es	<1%
49	Publicación	Mark Peelen, Leila Bagheriye, Johan Kwisthout. "Cancer Subtype Identification Th...	<1%
50	Publicación	Stephen A. Adefegha, Patricia O. Ogundare, Ganiyu Oboh. "Comparative Analysis ...	<1%
51	Internet	archiv.ub.uni-heidelberg.de	<1%
52	Internet	repositorioinstitucional.uabc.mx	<1%
53	Trabajos del estudiante	Noroff University College	<1%

54	Internet	kjar.spu.edu.iq	<1%
55	Trabajos del estudiante	Colegio Universitario de Estudios Financiero	<1%
56	Internet	d-nb.info	<1%
57	Internet	espanol.libretexts.org	<1%
58	Internet	vitela.javerianacali.edu.co	<1%
59	Trabajos del estudiante	Universitat Internacional de Catalunya	<1%
60	Internet	www.bright-journal.org	<1%
61	Trabajos del estudiante	Corporación Universitaria Minuto de Dios, UNIMINUTO	<1%
62	Publicación	Muhammad Saeed, Muhammad Arham, Imran Zafar, Adil Jamal et al. "Harnessin...	<1%
63	Internet	ocw.um.es	<1%
64	Publicación	Dimitria Brempou, Bertille Montibus, Louise Izatt, Cynthia L Andoniadou, Rebecc...	<1%
65	Publicación	Kaniz Fahima, Md Raiyan Hosen, Zimam Mahmud. "Comprehensive epigenomic a...	<1%
66	Trabajos del estudiante	Universidad Europea de Madrid	<1%
67	Internet	downloads.hindawi.com	<1%

68	Internet	revistarenal.org.ar	<1%
69	Publicación	Ana Luiza da Costa Terço, Cristine Souza Dos Santos, Luciana Bezerra Munhoz, Gr...	<1%
70	Publicación	García, Adriana Alvarado. "Designing Human-Centered Technologies to Mobilize ...	<1%
71	Internet	dokumen.pub	<1%
72	Internet	es.prohealth.com	<1%
73	Internet	minerva.usc.gal	<1%
74	Internet	patents.google.com	<1%
75	Internet	repositorio.continental.edu.pe	<1%
76	Internet	repository.eafit.edu.co	<1%
77	Internet	research.library.mun.ca	<1%
78	Internet	www.educarioja.org	<1%
79	Internet	doku.pub	<1%
80	Internet	idus.us.es	<1%
81	Internet	repositorio.unne.edu.ar	<1%

82	Internet	revistas.ufps.edu.co	<1%
83	Internet	revistas.unisimon.edu.co	<1%
84	Internet	sportouders.eu	<1%
85	Internet	www.esteve.org	<1%
86	Internet	www.incibe.es	<1%
87	Internet	www.medrxiv.org	<1%
88	Internet	www.revespcardiol.org	<1%
89	Internet	www.slideshare.net	<1%
90	Internet	www.studocu.com	<1%
91	Internet	1library.co	<1%
92	Publicación	Roca, Jose Luis Casteleiro. "Modelado de Sistemas Complejos Mediante Metodos ...	<1%
93	Trabajos del estudiante	Trident University International	<1%
94	Internet	appswl.elsevier.es	<1%
95	Internet	cerebrodigital.org	<1%

96	Internet	congresos.sebbm.es	<1%
97	Internet	iris.polito.it	<1%
98	Internet	iturbe.info	<1%
99	Internet	laccei.org	<1%
100	Internet	patologiagrupod4.wordpress.com	<1%
101	Internet	public-pages-files-2025.frontiersin.org	<1%
102	Internet	reunir.unir.net	<1%
103	Internet	ri.uaemex.mx	<1%
104	Internet	web.ujat.mx	<1%
105	Internet	www.cancerquest.org	<1%
106	Internet	www.eurisles.org	<1%
107	Internet	www.grafiati.com	<1%
108	Internet	www.theinsightpartners.com	<1%
109	Publicación	Barbosa Hernández, Camilo Andrés. "Modelo de clasificación de riesgo para prev..."	<1%

110

Publicación

Garcia Laencina, Pedro Jose. "Aprendizaje Maquina para Imputacion y Clasificacio... <1%

111

Publicación

S. Chandan, C.P. Bhargavi, H. Raja Naika. "Leveraging digital twin technology wit... <1%

112

Publicación

Jisha Augustine, A. S. Jereesh. "Identification of gene-level methylation for diseas... <1%

2



Universidad Politécnica
de Madrid



Escuela Técnica Superior de
Ingenieros Informáticos

Grado en Ingeniería Informática

Trabajo Fin de Grado

4

Análisis de Técnicas de IA para Predecir el Efecto de los Perfiles de Metilación del Genoma en Pacientes con Cáncer de Mama

Autor: Diego Armenteros Riaza

Tutor(a): Alfonso Rodríguez-Patón Aradas

Madrid, Junio 2026

Este Trabajo Fin de Grado se ha depositado en la ETSI Informáticos de la Universidad Politécnica de Madrid para su defensa.

Trabajo Fin de Grado

Grado en Ingeniería Informática

Título: Análisis de Técnicas de IA para Predecir el Efecto de los Perfiles de Metilación del Genoma en Pacientes con Cáncer de Mama

Junio 2026

Autor: Diego Armenteros

Tutor:

Alfonso Rodríguez-Patón Aradas
Departamento de Inteligencia Artificial
ETSI Informáticos
Universidad Politécnica de Madrid

Resumen

4

Este Trabajo de Fin de Grado analiza la aplicación de técnicas de inteligencia artificial al estudio de perfiles de metilación del ADN en cáncer de mama. La metilación es un mecanismo epigenético relacionado con la regulación de la expresión génica, y sus alteraciones pueden participar en el desarrollo y progresión tumoral. Por ello, los perfiles de metilación constituyen una fuente de información útil para estudiar diferencias entre tejido tumoral y tejido normal, así como para explorar su relación con la evolución clínica de los pacientes.

17

Para la parte experimental se utilizaron datos públicos del proyecto TCGA-BRCA, obtenidos mediante la plataforma Illumina HumanMethylation450. En primer lugar, se planteó una tarea de clasificación entre muestras tumorales primarias y muestras normales sólidas. Tras el filtrado y balanceo de clases, se trabajó con 194 muestras, 97 tumorales y 97 normales. Debido al elevado número inicial de posiciones CpG, se seleccionaron las 1000 posiciones con mayor varianza y los valores ausentes restantes se imputaron mediante la mediana de cada CpG.

Se compararon distintos modelos de aprendizaje automático y aprendizaje profundo, entre ellos regresión logística, SVM, Random Forest, Naive Bayes, J48, k-nearest neighbors, AdaBoostM1, MLP y un enfoque basado en autoencoder. Los modelos se evaluaron mediante validación cruzada estratificada de 10 particiones utilizando Weka. Los resultados de la clasificación tumoral fueron elevados en la mayoría de los modelos, destacando especialmente la SVM. También se analizaron algunas posiciones CpG relevantes, entre ellas cg11717189, que apareció como importante tanto en la regresión logística como en la SVM.

6

Además, se realizó un segundo análisis exploratorio orientado a la evolución clínica de los pacientes. Para ello, se combinaron los perfiles de metilación con información clínica y se definió una variable binaria de supervivencia a 5 años, diferenciando entre buena y mala evolución. En este caso, los resultados fueron más moderados.

En resumen, los resultados muestran que los perfiles de metilación contienen información útil para diferenciar entre muestras tumorales y normales en cáncer de mama. Sin embargo, la predicción de la evolución clínica resultó más compleja y debe interpretarse como una primera aproximación exploratoria.

4

Abstract

This Final Degree Project analyzes the application of artificial intelligence techniques to the study of DNA methylation profiles in breast cancer. Methylation is an epigenetic mechanism related to the regulation of gene expression, and its alterations may contribute to tumor development and progression. Therefore, methylation profiles represent a useful source of information for studying differences between tumor tissue and normal tissue, as well as for exploring their relationship with patients' clinical evolution.

For the experimental part, public data from the TCGA-BRCA project were used, obtained through the Illumina HumanMethylation450 platform. First, a classification task was proposed to distinguish between primary tumor samples and solid normal tissue samples. After filtering and class balancing, 194 samples were used: 97 tumor samples and 97 normal samples. Due to the high initial number of CpG positions, the 1000 positions with the highest variance were selected, and the remaining missing values were imputed using the median of each CpG.

Different machine learning and deep learning models were compared, including logistic regression, SVM, Random Forest, Naive Bayes, J48, k-nearest neighbors, AdaBoostM1, MLP, and an autoencoder-based approach. The models were evaluated using stratified 10-fold cross-validation in Weka. The results of tumor classification were high in most models, with SVM standing out. Some relevant CpG positions were also analyzed, including cg11717189, which appeared as important in both logistic regression and SVM.

In addition, a second exploratory analysis focused on the clinical evolution of patients was carried out. For this purpose, methylation profiles were combined with clinical information, and a binary 5-year survival variable was defined, distinguishing between good and poor evolution. In this case, the results were more moderate.

In summary, the results show that methylation profiles contain useful information for distinguishing between tumor and normal samples in breast cancer. However, predicting clinical evolution proved to be more complex and should be interpreted as a first exploratory approach.

Tabla de contenidos

1 Introducción	1
2 Fundamentos biológicos y técnicas de inteligencia artificial	2
2.1 Introducción a la metilación	2
2.1.1 Definición y función de la metilación	2
2.1.2 Patrones de metilación y alteraciones	2
2.1.2.1 Envejecimiento epigenético	3
2.1.2.2 Consumo de drogas	3
2.1.2.3 Estrés	3
2.2 Aspectos clave de la metilación	4
2.2.1 Islas CpG	4
2.2.2 Mantenimiento y cambio de los patrones de metilación	4
2.2.3 Desmetilación	5
2.2.4 Histonas	5
2.2.4.1 Modificación de histonas	6
2.3 Cáncer de mama y su relación con la metilación	7
2.3.1 Contexto	7
2.3.2 Alteraciones de la metilación relacionadas con el cáncer	7
2.3.3 Clasificación del cáncer de mama	8
2.3.3.1 Genes estudiados en el cáncer de mama	9
2.3.4 Perspectiva pan-cáncer	10
2.4 Técnicas de IA para la clasificación de perfiles de metilación	11
2.4.1 Planteamiento del problema de clasificación	11
2.4.2 Características de los datos de metilación	12
2.4.3 Preprocesamiento y selección de características	13
2.4.4 Modelos de aprendizaje automático clásicos	15
2.4.5 Modelos de aprendizaje profundo	16
2.4.6 Evaluación de modelos	18
2.4.7 Interpretabilidad de los modelos	22
3 Resultados y conclusiones	25
3.1 Conjuntos de datos y metodología	25
3.2 Análisis de clasificación tumoral	27
3.3 Análisis de evolución de los pacientes	41
3.4 Conclusiones	52
4 Análisis de Impacto	54
5 Bibliografía	55
6 Anexos	56

1 Introducción

En las últimas décadas, el estudio del cáncer ha experimentado un gran avance gracias al desarrollo de nuevas herramientas de análisis molecular y computacional. Aunque tradicionalmente la investigación oncológica se ha centrado en las alteraciones genéticas, cada vez existe una mayor evidencia de que los mecanismos epigenéticos también desempeñan un papel fundamental en la aparición, desarrollo y progresión de esta enfermedad. Entre estos mecanismos, la metilación del ADN destaca por su importancia en la regulación de la expresión génica y en el mantenimiento del funcionamiento normal de las células.

Cuando este proceso se altera, pueden producirse cambios anómalos en la expresión génica que favorezcan el desarrollo de distintos tipos de cáncer. En este contexto, el análisis de los perfiles de metilación se ha convertido en una línea de investigación de gran interés, ya que permite estudiar diferencias entre tejidos sanos y tumorales, así como identificar posibles biomarcadores útiles para el diagnóstico y el pronóstico clínico.

Paralelamente, la inteligencia artificial ha adquirido una relevancia creciente en el ámbito biomédico debido a su capacidad para procesar grandes volúmenes de datos complejos y extraer patrones que no siempre son fácilmente detectables mediante métodos estadísticos convencionales. En el caso concreto de los datos genómicos y epigenéticos, el uso de técnicas de IA ofrece una oportunidad para mejorar la clasificación de muestras biológicas y apoyar la toma de decisiones en investigación y medicina personalizada.

A partir de esta idea, el presente Trabajo de Fin de Grado se centra en el análisis de técnicas de inteligencia artificial aplicadas a la predicción del efecto de los perfiles de metilación del genoma en pacientes oncológicos, en concreto a la diferenciación entre pacientes sanos y pacientes con cáncer de mama. Para ello, se aborda en primer lugar el estudio de la metilación del ADN y su relación con el cáncer, con el fin de establecer una base teórica sólida que permita comprender la relevancia biológica del problema. Posteriormente, se analizan distintas técnicas de inteligencia artificial orientadas a la clasificación de perfiles de metilación, evaluando su comportamiento a partir de datos reales.

El objetivo general de este trabajo es analizar la utilidad de distintas técnicas de inteligencia artificial para la clasificación de perfiles de metilación del genoma, estudiando su aplicación en la diferenciación entre pacientes sanos y pacientes con cáncer de mama a partir de datos reales.

De este objetivo general se derivan los siguientes objetivos específicos:

- Estudio de la metilación del genoma humano y su efecto en el cáncer.
- Estudio de técnicas de IA para la clasificación de perfiles de metilación en genomas de pacientes sanos/con cáncer de mama.
- Comparación de estas técnicas empleando datos de metilación reales.
- Análisis de resultados y conclusiones

2 Fundamentos biológicos y técnicas de inteligencia artificial

2.1 Introducción a la metilación

2.1.1 Definición y función de la metilación

Dentro de la epigenética, la metilación se refiere a un proceso relacionado con la expresión de genes. La metilación del ADN consiste en la incorporación de un grupo metilo al quinto carbono de una citosina. Esta reacción está catalizada por enzimas ADN-metiltransferasas, que utilizan la S-adenosilmetionina (SAM) como donador del grupo metilo, dando lugar a la formación de 5-metilcitosina [1].

La metilación del ADN es un mecanismo epigenético necesario para el correcto funcionamiento de las células, especialmente en sistemas complejos como el sistema inmunitario. La alteración de este mecanismo provoca cambios en el comportamiento de las células y favorece el desarrollo de enfermedades, ya que la metilación cumple un papel como regulador de la expresión génica, implicado en distintos procesos fisiológicos y patológicos [2].

2.1.2 Patrones de metilación y alteraciones

Los patrones de metilación se refieren a la distribución en el genoma de las marcas de metilación. Estos patrones constituyen un sistema de regulación epigenética que permite a las células adaptar su funcionamiento. Al no ser estáticos, los patrones pueden modificarse durante el envejecimiento o verse alterados por influencias ambientales, como el consumo de sustancias, o exposiciones prolongadas al estrés. Los cambios en la metilación del ADN pueden tener consecuencias significativas sobre la expresión génica y el equilibrio celular, involucrándose con procesos fisiológicos normales y el desarrollo de alteraciones patológicas. Es por ello que el estudio de los patrones de metilación y de los factores que los modifican resulta clave para entender cómo el entorno y el estilo de vida influyen en la regulación genética [3].

2.1.2.1 Envejecimiento epigenético

El envejecimiento tiene una gran influencia sobre los patrones de metilación del ADN. A medida que envejecemos acumulamos alteraciones epigenéticas que afectan a la regulación de los genes. Estas alteraciones no se producen en zonas aleatorias, sino que tienden a concentrarse en zonas específicas del genoma [3].

2.1.2.2 Consumo de drogas

El consumo de drogas, ya sea por ocio o por tratamientos, puede alterar los patrones de metilación. Estas alteraciones pueden modificar la expresión génica en distintos órganos, afectando desde el aparato reproductor y la fertilidad hasta el mismo cerebro. Si estos cambios ocurren durante el desarrollo fetal, pueden mantenerse hasta la edad adulta, con la posibilidad de transmitirse a la descendencia [3].

2.1.2.3 Estrés

El estrés aparte de afectar a la salud mental también puede afectar a la metilación, dejando marcas epigenéticas duraderas. Estas modificaciones muestran cómo las experiencias e influencias ambientales pueden influir en la expresión génica sin alterar la secuencia de ADN necesariamente. Tanto episodios de estrés agudo como exposición prolongada al estrés se asocian con cambios medibles en la metilación de regiones específicas del genoma en tejidos como sangre y saliva.

El estrés no solo se manifiesta a nivel emocional, sino que provoca respuestas fisiológicas como la liberación de hormonas, entre las que se encuentra el cortisol. Estas hormonas pueden influir en las enzimas encargadas de mantener y establecer marcas epigenéticas, variando la metilación de genes implicados en la regulación del sistema nervioso y en la respuesta hormonal. Como ejemplo, la exposición a estrés o experiencias traumáticas durante la infancia están relacionadas con patrones alterados de metilación en genes vinculados a la regulación de emociones y la plasticidad neuronal. Estas alteraciones epigenéticas inducidas por el estrés pueden mantenerse a lo largo del tiempo y contribuir a la aceleración del envejecimiento biológico. Esto se ha podido comprobar en estudios con relojes epigenéticos, donde las células mostraban patrones de metilación similares a individuos más envejecidos [4].

El impacto del estrés también se relaciona con enfermedades mentales y trastornos de la conducta. Los cambios en la metilación de genes que regulan neurotransmisores y la respuesta al estrés ayudan a explicar por qué algunos

individuos son más vulnerables a trastornos como la ansiedad, depresión o estrés postraumático. Estas alteraciones epigenéticas no solo se vinculan a la aparición de síntomas, sino que también tienen un efecto transgeneracional, siendo heredadas incluso tras la desaparición del estímulo estresante.

9 Todo esto da a entender que el estrés es un factor ambiental capaz de reprogramar la metilación del ADN, teniendo consecuencias a nivel de salud mental, la forma en la que los individuos responden a futuros estímulos, envejecimiento y susceptibilidad a diferentes patologías.

2.2 Aspectos clave de la metilación

2.2.1 Islas CpG

59 Las posiciones CpG son regiones del ADN en las que una citosina se encuentra seguida de una guanina en la misma cadena. Estas posiciones tienen un papel importante en la regulación de la expresión génica, ya que su estado de metilación puede influir en la activación o silenciamiento de determinados genes.

5 En algunas zonas del genoma, las posiciones CpG se encuentran agrupadas formando regiones conocidas como islas CpG. Estas islas suelen localizarse en promotores de genes implicados en funciones celulares básicas y, en condiciones normales, tienden a permanecer poco metiladas. Sin embargo, alrededor de ellas existen regiones próximas, denominadas orillas de islas CpG, que presentan una menor concentración de posiciones CpG y cuya metilación se ha relacionado con cambios en la regulación génica, incluida la represión de la expresión de determinados genes [2].

2.2.2 Mantenimiento y cambio de los patrones de metilación

14 5 En las células somáticas, los patrones de metilación del ADN se mantienen después de cada división celular gracias a la acción de la ADN metiltransferasa 1 (DNMT1). Durante la replicación, la hebra nueva de ADN se sintetiza inicialmente sin las mismas marcas de metilación que la hebra original, dando lugar a moléculas hemimetiladas. DNMT1 reconoce estas regiones y restablece la metilación en la hebra recién sintetizada, permitiendo conservar el patrón epigenético entre generaciones celulares. Además de este mecanismo de mantenimiento, existen enzimas como DNMT3A y DNMT3B, consideradas metiltransferasas de novo, capaces de establecer nuevos patrones de metilación en regiones que previamente no estaban metiladas.

Estas enzimas son especialmente importantes durante el desarrollo embrionario, cuando las células van adquiriendo funciones especializadas y se establecen muchos de los patrones epigenéticos propios de cada tipo celular [3].

2.2.3 Desmetilación

En un estudio de 2009 publicado en la revista Science [5] se comprobó como unas proteínas de la familia TET (ten eleven translocation), concretamente TET1, eran capaces de modificar la 5-metilcitosina actuando como catalizador en una oxidación de estas citosinas metiladas, demostrando que los patrones de metilación no son fijos.

Dado que las alteraciones en los patrones de metilación se han relacionado con el desarrollo de distintos tipos de cáncer, las proteínas TET adquieren una especial relevancia en este contexto. Al participar en la regulación dinámica de la metilación del ADN, estas enzimas pueden contribuir al mantenimiento de un equilibrio epigenético adecuado. Cuando su función se altera, debido a mutaciones o pérdida de actividad, pueden producirse cambios anómalos en la metilación que favorezcan procesos asociados a enfermedades. En concreto, se han descrito mutaciones en TET2 en pacientes con trastornos hematológicos, lo que refuerza la relación entre la alteración de estas proteínas y determinadas patologías.

2.2.4 Histonas

Las histonas son proteínas básicas que, junto con el ADN, forman la cromatina. Su función principal es permitir que la molécula de ADN, debido a su gran longitud, pueda organizarse adecuadamente dentro del núcleo celular. Para ello, el ADN se enrolla alrededor de complejos de histonas formando nucleosomas, que constituyen la unidad básica de la cromatina [6].

Esta organización facilita el empaquetamiento del material genético y contribuye a mantener una estructura ordenada dentro del núcleo. Además, las histonas participan en la estabilidad del ADN y en la organización de las distintas regiones del genoma. Por tanto, no solo cumplen una función estructural, sino que también forman parte del contexto epigenético.

2.2.4.1 Modificación de histonas

La metilación del ADN y las modificaciones de las histonas son dos de los principales mecanismos epigenéticos implicados en la regulación de la expresión génica. La metilación del ADN se asocia frecuentemente con el silenciamiento génico, especialmente cuando afecta a regiones reguladoras

25 como los promotores. De forma complementaria, las modificaciones de las histonas pueden alterar el grado de compactación de la cromatina, haciendo que determinadas regiones del ADN queden más accesibles o más ocultas para los factores que participan en la transcripción.

23 Ambos mecanismos no actúan de forma aislada, sino que pueden coordinarse entre sí. Por ejemplo, la metilación del ADN puede servir como señal de reconocimiento para proteínas que se unen a regiones metiladas. Estas proteínas pueden reclutar enzimas capaces de modificar las histonas cercanas, favoreciendo una mayor compactación de la cromatina y reforzando el silenciamiento génico. De esta manera, la metilación del ADN y las modificaciones de las histonas pueden cooperar para establecer estados epigenéticos más estables.

8 96 Esta cooperación permite mantener patrones de expresión génica a lo largo de las divisiones celulares, lo que resulta especialmente importante durante el desarrollo embrionario y la diferenciación celular. Gracias a estos mecanismos, las células pueden conservar información sobre qué genes deben permanecer activos y cuáles deben mantenerse silenciados, sin necesidad de modificar la secuencia del ADN.

5 100 Cuando se altera la coordinación entre la metilación del ADN y las modificaciones de las histonas, pueden generarse patrones anómalos de regulación génica. En el contexto del cáncer, esto puede favorecer el silenciamiento de genes que normalmente limitan la proliferación celular o participan en el control del ciclo celular, contribuyendo así al desarrollo y progresión tumoral [6].

2.3 Cáncer de mama y su relación con la metilación

2.3.1 Contexto

68 El cáncer de mama es una enfermedad heterogénea, tanto desde el punto de vista clínico como molecular. Aunque todos los tumores se originan en el tejido mamario, pueden presentar diferencias importantes en su comportamiento biológico, agresividad, capacidad de progresión y respuesta al tratamiento. Por este motivo, su estudio no puede limitarse únicamente a la presencia del tumor, sino que requiere analizar las características moleculares que distinguen unos casos de otros.

Tradicionalmente, la investigación oncológica se ha centrado en alteraciones genéticas, como mutaciones o cambios en el número de copias de

determinados genes. Sin embargo, en los últimos años ha cobrado importancia el estudio de los mecanismos epigenéticos, entre ellos la metilación del ADN, debido a su papel en la regulación de la expresión génica.

El análisis de perfiles de metilación resulta especialmente relevante porque puede aportar información complementaria a la clasificación clínica tradicional. Tumores clasificados dentro de un mismo grupo clínico pueden mostrar diferencias epigenéticas que ayuden a explicar variaciones en su evolución, pronóstico o respuesta terapéutica.

Además, los perfiles de metilación generan una gran cantidad de información molecular, ya que permiten analizar simultáneamente miles de regiones CpG distribuidas por el genoma. Esta característica los convierte en datos adecuados para su estudio mediante técnicas computacionales e inteligencia artificial, capaces de identificar patrones complejos asociados al estado tumoral o a la evolución clínica de los pacientes.

Por tanto, el estudio de la metilación en cáncer de mama constituye un punto de unión entre la biología molecular del cáncer y el análisis computacional de datos biomédicos.

2.3.2 Alteraciones de la metilación relacionadas con el cáncer

En el contexto del cáncer, una alteración frecuente es la hipermetilación local de promotores de genes supresores tumorales. Este fenómeno puede provocar el silenciamiento de genes que normalmente participan en el control del ciclo celular, la reparación del ADN, la apoptosis o la inhibición de la proliferación celular. Como consecuencia, la célula cancerígena puede adquirir ventajas proliferativas, escapando de mecanismos normales de control. Además de la hipermetilación, los tumores suelen mostrar hipometilación global del genoma, especialmente en regiones repetitivas o regiones pobres en CpG. Esta pérdida de metilación puede favorecer la inestabilidad genómica y la aparición de alteraciones cromosómicas [7].

Por tanto, el cáncer no se puede definir simplemente como más o menos metilación, sino por una reorganización anómala del paisaje epigenético. De forma general, puede coexistir una hipometilación global del genoma con una hipermetilación específica de promotores de genes reguladores. Esta combinación altera tanto la estabilidad del genoma como la expresión selectiva de genes clave para la carcinogénesis.

Desde un punto de vista clínico, estas alteraciones epigenéticas son relevantes porque pueden emplearse como biomarcadores. A diferencia de muchas mutaciones genéticas, los cambios de metilación pueden aparecer de forma

temprana durante la carcinogénesis y ser detectables en muestras biológicas. Por ello, el análisis de metilación del ADN se ha propuesto para mejorar el diagnóstico precoz, la clasificación molecular de tumores, la estimación del pronóstico y la predicción de respuesta a determinados tratamientos.

2.3.3 Clasificación del cáncer de mama

Desde el punto de vista clínico, la clasificación divide los tumores de mama en grupos: los que expresan muchos receptores de progesterona y estrógenos, denominadas mamas hormonales, en las que se encuentran los fenotipos luminales A y B en función de cuánto de proliferante sea la mama y de cuántos receptores haya presentes; los que expresan el marcador HER2/neu, que con amplificación de ese gen tienen tratamiento; y el fenotipo triple negativo, que es el más complicado ya que no expresan HER2/neu ni receptores de progesterona o estrógenos. Este último es el que peor pronóstico tiene ya que no se puede realizar bloqueo hormonal ni hacer tratamiento dirigido contra HER2.

Sin embargo, esta clasificación clínica no recoge toda la diversidad biológica del cáncer de mama. Tumores incluidos dentro de un mismo grupo pueden presentar diferencias importantes en agresividad, respuesta al tratamiento, riesgo de recaída y supervivencia. En este contexto, las marcas epigenéticas y la metilación del ADN pueden ayudar a explicar diferencias biológicas y clínicas no captadas por los marcadores convencionales. En particular, se ha observado que determinados patrones de metilación se asocian con fenotipos concretos, como el luminal B, caracterizado por eventos de metilación en islas CpG de regiones promotoras.

2.3.3.1 Genes estudiados en el cáncer de mama

Entre los genes más relevantes en cáncer de mama se encuentra BRCA1. Dado que BRCA1 participa en la reparación del ADN mediante recombinación homóloga, su silenciamiento epigenético puede favorecer la acumulación de daño genético y la inestabilidad genómica. Este fenómeno se ha relacionado con tumores esporádicos y con mayor agresividad, especialmente en tumores de mama triple negativos [8].

Otros genes frecuentemente estudiados en cáncer de mama son RASSF1A y CDH1. RASSF1A actúa como gen supresor tumoral implicado en regulación del ciclo celular, apoptosis y estabilidad de microtúbulos, mientras que CDH1 codifica E-cadherina, una proteína clave en adhesión celular. La hipermetilación de estos promotores puede contribuir, respectivamente, a la alteración de la proliferación celular y a procesos relacionados con invasión tumoral y pérdida de adhesión celular [8].

La metilación también puede afectar a genes relacionados con la respuesta hormonal, como ESR1, que codifica el receptor de estrógenos alfa. Alteraciones de estos genes pueden tener relevancia en tumores dependientes de hormonas y en mecanismos de resistencia a terapias endocrinas [8].

En conjunto, estos ejemplos muestran que la metilación del ADN puede afectar a genes implicados en procesos clave del cáncer de mama, como la reparación del ADN, el control de la proliferación celular, la adhesión entre células, la invasión tumoral y la respuesta hormonal. Por tanto, el estudio de estos cambios epigenéticos permite comprender mejor la variedad del cáncer de mama y puede aportar información complementaria a la clasificación clínica tradicional. Esta información resulta especialmente útil para identificar posibles biomarcadores relacionados con el pronóstico, la progresión tumoral o la respuesta a determinados tratamientos.

2.3.4 Perspectiva pan-cáncer

Desde una perspectiva pan-cáncer, el estudio de la metilación del ADN permite comparar distintos tipos tumorales bajo un mismo marco. En lugar de analizar cada cáncer de forma aislada, se integran datos procedentes de múltiples tumores para identificar tanto alteraciones epigenéticas comunes como patrones específicos de cada tejido.

Un gran hallazgo es que muchos tumores comparten cambios epigenéticos similares [9]. Estos cambios pueden afectar a mecanismos generales de la oncogénesis, como el silenciamiento de genes supresores tumorales, la pérdida de estabilidad genómica y la alteración de expresión génica.

Sin embargo, los perfiles de metilación también se vinculan con el tejido o la célula de origen. Esto significa que, aunque dos tumores de órganos distintos puedan compartir mecanismos epigenéticos comunes, cada tipo tumoral mantiene características propias derivadas del tejido del que procede. Por este motivo, la metilación del ADN puede ser útil tanto para estudiar procesos generales del cáncer como para diferenciar tumores según su origen.

Esta información resulta especialmente relevante para la clasificación molecular. Por un lado, permite identificar subtipos tumorales dentro de un mismo cáncer, como ocurre en el cáncer de mama. Por otro lado, permite detectar similitudes entre tumores de diferentes localizaciones anatómicas, lo que puede facilitar la identificación de mecanismos comunes de progresión tumoral y de posibles tratamientos compartidos entre distintos tipos de cáncer.

En el contexto de este trabajo, la perspectiva pan-cáncer demuestra que la metilación no es un fenómeno aislado de un único tumor, sino una fuente de información común y comparable entre distintos tipos de cáncer. Esto justifica el uso de perfiles de metilación como fuente de información para modelos predictivos. La metilación del ADN proporciona datos de alta dimensionalidad capaces de reflejar tanto características generales como específicas de cada tipo de cáncer. Por ello, su análisis mediante técnicas de inteligencia artificial puede contribuir a identificar patrones asociados con la evolución clínica de los pacientes, el pronóstico o la respuesta al tratamiento.

2.4 Técnicas de IA para la clasificación de perfiles de metilación

Una vez establecida la relación entre la metilación del ADN y el cáncer de mama, el siguiente paso consiste en estudiar cómo pueden utilizarse estos perfiles como datos de entrada para modelos de inteligencia artificial. En esta sección se plantea el problema de clasificación, se describen las características computacionales de los datos de metilación y se revisan distintas técnicas aplicables.

2.4.1 Planteamiento del problema de clasificación

El problema puede plantearse como una tarea de aprendizaje supervisado, en la que el modelo recibe como entrada los perfiles de metilación y aprende a asociarlos con una etiqueta de clase, por ejemplo, muestra sana o muestra tumoral de cáncer de mama. Para ello, es necesario disponer de un conjunto de datos previamente etiquetado, dividirlo en conjuntos de entrenamiento y evaluación, y utilizar métricas que permitan valorar el rendimiento del modelo de forma objetiva.

Los perfiles de metilación presentan una dificultad computacional importante debido a su alta dimensionalidad. Una sola muestra puede contener información de miles o cientos de miles de posiciones CpG, mientras que el número de pacientes disponibles es mucho menor. Esta diferencia entre el número de variables y el número de muestras aumenta el riesgo de sobreajuste, es decir, que el modelo aprenda patrones específicos del conjunto de entrenamiento pero no sea capaz de generalizar correctamente a nuevos pacientes. Por este motivo, el análisis de perfiles de metilación requiere una metodología cuidadosa que incluya preprocesamiento de datos, selección de características, elección adecuada del modelo y validación rigurosa.

En este contexto, las técnicas de inteligencia artificial son útiles porque permiten analizar de forma conjunta un gran número de regiones del genoma e identificar combinaciones de señales de metilación que podrían estar asociadas al estado de la muestra o a variables clínicas relevantes.

En este apartado se estudian distintas familias de métodos aplicables a este problema, desde modelos clásicos de aprendizaje automático hasta enfoques de aprendizaje profundo, prestando atención a sus ventajas, limitaciones e interpretabilidad en el análisis de datos de metilación.

2.4.2 Características de los datos de metilación

Los datos de metilación del ADN utilizados en estudios computacionales representan el nivel de metilación de múltiples posiciones CpG distribuidas por el genoma. En plataformas de microarrays cada muestra se describe mediante un gran número de mediciones asociadas a regiones concretas del ADN. Esto permite obtener una representación amplia del estado epigenético de una muestra a cambio de aumentar el coste computacional, como se ha mencionado anteriormente [10].

Una forma habitual de representar los datos es mediante valores beta. Estos valores indican el grado de metilación de cada posición CpG en una escala entre 0 y 1, donde los valores cercanos a 0 representan baja metilación y los valores cercanos a 1 alta metilación. Esta representación es útil porque resulta fácil de interpretar. Además de los valores beta, también se pueden utilizar valores M, que transforman la relación entre la señal metilada y no metilada mediante una escala logarítmica. En general, los valores M no son tan fáciles de interpretar como los beta, pero pueden ser más adecuados para análisis estadísticos [11].

Estos datos suelen organizarse en forma de matriz, donde las filas representan muestras y las columnas corresponden a posiciones CpG o sondas del array. Cada celda contiene el valor de metilación de una posición y una muestra concreta. De esta forma, una muestra no queda descrita por una única medida, sino por un perfil formado por un gran número de valores.

Otra característica importante es que cada posición CpG puede estar asociada a una región del genoma. Por ejemplo, pueden estar localizadas en una región reguladora, en el cuerpo de un gen o en una isla CpG. Esta información es relevante porque ayuda a interpretar biológicamente los valores de metilación observados, ya que la consecuencia funcional de la metilación puede variar según la región genómica en la que se produzca.

Los perfiles de metilación también pueden contener variabilidad que no procede únicamente de diferencias biológicas reales. Factores como la calidad de la muestra, la plataforma utilizada, o el procesamiento aplicado pueden influir en los valores obtenidos. Por este motivo, los datos de metilación deben entenderse como datos experimentales susceptibles a factores técnicos.

En conjunto, los datos de metilación se caracterizan por ser perfiles moleculares continuos, de gran tamaño y asociados a posiciones genómicas concretas. Esta estructura permite estudiar de forma detallada el estado epigenético de una muestra, pero también exige interpretar los valores teniendo en cuenta su localización genómica, la escala utilizada para representarlos y las posibles fuentes de variabilidad.

2.4.3 Preprocesamiento y selección de características

Antes de aplicar modelos de inteligencia artificial, los perfiles de metilación deben pasar por una fase de preprocesamiento. El objetivo de esta etapa es reducir errores técnicos y preparar los datos para que las diferencias observadas entre muestras reflejen variaciones biológicas reales. En el caso de los arrays de metilación, paquetes como minfi incluyen funciones específicas para importar los datos, realizar control de calidad, normalizar las señales y trabajar con plataformas como Illumina 450K y EPIC [12].

Una primera fase consiste en realizar un control de calidad de las muestras y de las sondas. Este paso permite detectar mediciones poco fiables, muestras con baja calidad o posiciones CpG que no deberían considerarse en el análisis. En estudios con arrays de metilación, el filtrado inicial es importante porque algunas señales pueden estar afectadas por problemas técnicos, baja intensidad o diferencias entre plataformas.

Después del control de calidad suele aplicarse una etapa de normalización. Esta fase busca hacer que las muestras sean comparables entre sí, reduciendo variaciones introducidas por el procedimiento experimental. En datos procedentes de arrays, la normalización es especialmente importante porque las intensidades medidas pueden depender de factores técnicos y no solo del estado de metilación real de la muestra.

Otro aspecto a tener en cuenta son los efectos de lote. Estos aparecen cuando las muestras han sido procesadas en momentos diferentes, con reactivos distintos, en laboratorios distintos o bajo condiciones experimentales distintas. Si no se controlan, el modelo puede aprender diferencias asociadas al lote en lugar de patrones relacionados con el cáncer. Por ello, en estudios de metilación se han propuesto métodos específicos como ComBat-met para corregir este tipo de variabilidad técnica [13].

Una vez preparados los datos, suele ser necesario reducir el número de variables utilizadas por el modelo. No todas las posiciones CpG aportan la misma información para distinguir entre muestras sanas y tumorales, y algunas pueden introducir ruido. La selección de características permite identificar un subconjunto de variables más informativas, reduciendo la complejidad del problema y facilitando la construcción de modelos más estables. Este paso es habitual en estudios de metilación debido al gran número de CpGs analizadas en comparación con el número de muestras disponibles.

Existen distintas estrategias para seleccionar características. Algunas se basan en criterios estadísticos simples, como conservar las posiciones CpG con mayor variabilidad o con diferencias más marcadas entre grupos. Otras utilizan métodos integrados en el propio modelo, como ocurre con determinados algoritmos capaces de asignar importancia a cada variable. También pueden emplearse enfoques más complejos que combinan selección de características con modelos de aprendizaje automático o aprendizaje profundo. En cáncer de mama, se han propuesto metodologías que reducen el número de marcadores de metilación antes de entrenar modelos predictivos, con el objetivo de hacer el análisis más manejable y facilitar la interpretación de los genes implicados [14].

La selección de características también tiene una ventaja desde el punto de vista biológico. Al reducir el conjunto inicial de CpGs a un grupo más pequeño de posiciones relevantes, se puede comprobar si las posiciones seleccionadas están relacionadas con genes importantes en el desarrollo del cáncer. De esta forma, el modelo no solo se utiliza para clasificar muestras, sino también como herramienta para señalar posibles biomarcadores de interés.

Es importante que la selección de características se realice de forma correcta dentro del proceso de entrenamiento y evaluación. Si se seleccionan variables utilizando todos los datos antes de separar entrenamiento y prueba, puede introducirse información del conjunto de evaluación en el modelo, produciendo resultados demasiado optimistas. Por este motivo, algunos estudios emplean validación cruzada anidada o conjuntos de prueba independientes para evaluar de forma más fiable el rendimiento de modelos basados en metilación [15].

En resumen, el preprocesamiento y la selección de características son pasos esenciales para trabajar con perfiles de metilación. El primero permite mejorar la calidad y comparabilidad de los datos, mientras que la segunda reduce la complejidad del problema y ayuda a conservar las variables con mayor utilidad predictiva. Ambos pasos son especialmente relevantes en este trabajo, ya que

condicionan la calidad de los datos que posteriormente serán utilizados por los modelos de clasificación.

2.4.4 Modelos de aprendizaje automático clásicos

Los modelos clásicos de aprendizaje automático constituyen una primera aproximación adecuada para la clasificación de perfiles de metilación. Aunque en los últimos años han ganado importancia los modelos de aprendizaje profundo, los métodos clásicos siguen siendo muy utilizados porque suelen requerir menos complejidad computacional, son más fáciles de evaluar y, en algunos casos, ofrecen una mayor interpretabilidad. En estudios de metilación del ADN aplicados a cáncer se han utilizado algoritmos como máquinas de vectores soporte, random forest, k-nearest neighbors, naive Bayes, regresión logística, y métodos basados en boosting [16].

En este trabajo, estos modelos resultan relevantes porque permiten abordar el problema como una tarea de clasificación supervisada. A partir de muestras previamente etiquetadas, por ejemplo como sanas o tumorales, el modelo aprende a asociar los valores de metilación con una clase concreta. Una vez entrenado, puede aplicarse sobre muestras no utilizadas durante el entrenamiento para comprobar si ha aprendido patrones útiles para diferenciar ambos grupos.

Uno de los modelos más sencillos y habituales es la regresión logística. Este se utiliza frecuentemente en problemas de clasificación binaria como distinguir entre dos clases. Su principal ventaja es que permite interpretar la contribución de las variables al resultado del modelo. La regresión logística puede utilizarse con técnicas de regularización, como LASSO, ridge o una combinación de ambas. Estas técnicas permiten reducir el peso de variables poco útiles y favorecer modelos más simples. Esto es especialmente interesante cuando se trabaja con muchas posiciones CpG y un número limitado de muestras [17].

También pueden utilizarse otros modelos sencillos como k-nearest neighbors y naive Bayes. K-nearest neighbors clasifica una muestra teniendo en cuenta las clases de las muestras más parecidas dentro del conjunto de entrenamiento. Naive Bayes, por su parte, se basa en estimar la probabilidad de que una muestra pertenezca a una clase a partir de sus variables. Aunque suelen emplearse como modelos de referencia, pueden ser útiles para comparar resultados y comprobar si métodos más complejos aportan realmente una mejora. [17].

Las máquinas de vectores soporte o SVM son otra familia de modelos ampliamente utilizada en clasificación biomédica. Su objetivo es encontrar

una separación entre clases en función de las variables de entrada. En perfiles de metilación, pueden ser útiles porque trabajan bien con datos de gran volumen [17].

Otro grupo importante son los modelos basados en árboles de decisión. Un árbol de decisión clasifica una muestra aplicando una secuencia de reglas sobre las variables de entrada. Sin embargo, un único árbol puede ser inestable si los datos son ruidosos. Para reducir este problema se utilizan métodos de conjunto como random forest, que construyen varios árboles y combinan sus decisiones [16].

Dentro de los métodos de conjunto también destacan los modelos de gradient boosting. Estos modelos construyen varios árboles de forma secuencial, de manera que cada nuevo árbol intenta corregir parte de los errores cometidos por los anteriores [16].

En el caso concreto del cáncer de mama, los modelos clásicos pueden utilizarse para distinguir muestras tumorales y sanas a partir de perfiles de metilación. Algunos de estos modelos, como random forest o la regresión logística regularizada, también pueden contribuir a identificar las variables más relevantes para la clasificación.

De esta forma, los modelos clásicos de aprendizaje automático ofrecen una base sólida para el análisis de perfiles de metilación. Su utilidad no se limita a obtener una clasificación, sino que también permiten comparar enfoques, establecer modelos de referencia e identificar variables relevantes. Por este motivo, resultan especialmente adecuados como punto de partida antes de estudiar métodos más complejos, como los modelos de aprendizaje profundo.

2.4.5 Modelos de aprendizaje profundo

Los modelos de aprendizaje profundo representan una alternativa a los modelos clásicos de aprendizaje automático cuando se trabaja con datos complejos y de alta dimensionalidad. En lugar de basarse en reglas simples o en una única transformación de los datos, estos modelos utilizan varias capas de procesamiento para combinar progresivamente la información de entrada y detectar patrones más complejos. En el contexto de la metilación del ADN, esto puede ser útil porque la diferencia entre una muestra sana y una tumoral puede depender de combinaciones complejas de múltiples posiciones CpG, y no únicamente de cambios aislados en una región concreta. En los últimos años, el aprendizaje profundo se ha incorporado progresivamente al análisis de datos epigenéticos en cáncer. En el caso de la metilación del ADN, se ha utilizado no solo para diferenciar tipos de muestras, sino también para

explorar patrones asociados con la enfermedad, completar información ausente en los datos y estudiar variables clínicas como la supervivencia [18].

Uno de los modelos dentro del aprendizaje profundo es el perceptrón multicapa o MLP. Este tipo de red neuronal recibe como entrada un conjunto de variables, las procesa a través de capas internas y genera una salida que puede representar la clase predicha. En un problema como el de este trabajo, la salida podría indicar si una muestra corresponde a tejido sano o a cáncer de mama. Su interés está en que puede aprender relaciones no lineales entre las posiciones CpG y la clase, aunque requiere controlar cuidadosamente el sobreajuste, especialmente cuando el número de muestras es reducido en comparación con el número de variables [18].

Dentro de los modelos de aprendizaje profundo también destacan los autoencoders. Estos modelos aprenden a comprimir los datos de entrada en una representación de menor dimensión y después intentan reconstruir la información original a partir de esa representación comprimida. En perfiles de metilación, esta idea resulta útil porque permite transformar un conjunto muy grande de posiciones CpG en un número menor de variables que resumen parte de la información contenida en el perfil original. Estas representaciones pueden emplearse posteriormente para clasificación, visualización de muestras o estudio de subgrupos [19].

Un ejemplo de aplicación de autoencoders al análisis de metilación es MethylNet, un marco diseñado específicamente para trabajar con perfiles de metilación del ADN. Este enfoque utiliza arquitecturas basadas en autoencoders para obtener representaciones reducidas de las muestras, que posteriormente pueden emplearse en tareas predictivas o exploratorias [19].

Otra familia de modelos que puede mencionarse son las redes neuronales convolucionales o CNN. Aunque se conocen sobre todo por su uso en imágenes, también se han explorado con datos genómicos y epigenómicos. En metilación, algunos trabajos han estudiado CNN para clasificar tipos de cáncer a partir de perfiles de metilación. Sin embargo, en este contexto su uso suele ser menos directo que en imágenes, porque los CpG no forman una cuadrícula natural, y por tanto es necesario decidir cómo ordenar o representar las variables de entrada [20].

También existen modelos de aprendizaje profundo orientados a la integración multi-ómica. En cáncer de mama, algunos estudios han combinado metilación del ADN con otros tipos de datos, como expresión génica, microARN o variaciones en número de copias, para mejorar la predicción de supervivencia o la clasificación de subtipos. Este tipo de enfoque es relevante porque la metilación aporta una parte de la información biológica, pero su combinación

con otros datos puede ofrecer una visión más completa del estado tumoral [21].

A pesar de sus ventajas, los modelos de aprendizaje profundo también presentan limitaciones importantes. Normalmente requieren más datos que los modelos clásicos para entrenar de forma fiable, y sus decisiones pueden ser más difíciles de interpretar. En biomedicina, esta falta de interpretabilidad puede ser un problema, ya que no sólo interesa obtener una predicción correcta, sino también comprender qué regiones del genoma o qué genes pueden estar relacionados con esa predicción.

47 En el contexto del cáncer de mama se han propuesto enfoques que combinan selección de características y aprendizaje profundo para trabajar con datos de metilación. Por ejemplo, en un estudio publicado en 2022 [14] se propone una tubería de análisis que combina selección de características y aprendizaje profundo para predecir cáncer de mama usando datos de metilación del ADN del conjunto TCGA-BRCA. Este tipo de trabajos muestra que, antes de aplicar una red neuronal, suele ser necesario reducir el número de variables para hacer el problema más manejable y disminuir el riesgo de que el modelo aprenda patrones poco generalizables.

En conclusión, los modelos de aprendizaje profundo no deben entenderse necesariamente como sustitutos directos de los modelos clásicos, sino como una familia de métodos complementaria. En algunos casos pueden capturar relaciones más complejas entre variables, mientras que en otros un modelo clásico bien ajustado puede ofrecer resultados similares con menor coste computacional y mayor interpretabilidad. Para este trabajo, su estudio resulta relevante porque permite comparar enfoques de distinta complejidad y valorar si el uso de arquitecturas profundas aporta una mejora real en la clasificación de perfiles de metilación.

2.4.6 Evaluación de modelos

9 La evaluación de los modelos es una fase esencial para determinar si un clasificador es realmente útil o si únicamente ha aprendido patrones específicos del conjunto de entrenamiento. En el caso de perfiles de metilación, esta evaluación debe realizarse con especial cuidado, ya que, como se ha mencionado anteriormente, el número de variables suele ser elevado y el número de muestras limitado. Por ello, no basta con entrenar un modelo y comprobar cuántas muestras acierta, sino que es necesario analizar su rendimiento mediante distintas métricas y con datos que no hayan sido utilizados durante el entrenamiento. En estudios de clasificación con perfiles de metilación se emplean estrategias como validación cruzada y métricas como

área bajo la curva (AUC), tasa de acierto, precisión, sensibilidad o especificidad para comparar modelos [16].

Una de las formas más básicas de evaluar un modelo de clasificación es mediante la matriz de confusión. Esta matriz compara las clases reales de las muestras con las clases predichas por el modelo. Es una clasificación binaria que permite distinguir entre verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos. A partir de estos valores se calculan distintas métricas que resumen el comportamiento del modelo desde perspectivas complementarias [22].

Tabla 1. Matriz de confusión

Clase predicha / Clase real	Clase +	Clase -
Clase +	Verdadero positivo (TP)	Falso positivo (FP)
Clase -	Falso negativo (FN)	Verdadero negativo (TN)

La accuracy o tasa de acierto mide la proporción total de predicciones correctas. Es una métrica sencilla de interpretar, pero puede ser insuficiente cuando las clases están desbalanceadas. Por ejemplo, si hay muchas más muestras sanas que tumorales, un modelo podría obtener una exactitud alta simplemente prediciendo la clase mayoritaria, aunque detecte mal los casos de cáncer. Por este motivo, en problemas biomédicos conviene acompañar la tasa de acierto de otras métricas [22].

$$\frac{TP+TN}{TP+FP+FN+TN}$$

La sensibilidad, también llamada recall o tasa de verdaderos positivos, mide la capacidad del modelo para identificar correctamente las muestras positivas. En este trabajo, si se considera como clase positiva el cáncer de mama, la sensibilidad indicaría qué proporción de muestras tumorales han sido detectadas correctamente. Esta métrica es especialmente importante en contextos clínicos, ya que un valor bajo implicaría que el modelo está dejando sin detectar un número elevado de casos tumorales [22].

10

La especificidad o tasa de verdaderos negativos mide la capacidad del modelo para reconocer correctamente las muestras negativas. En una clasificación entre tejido sano y tumoral, indicaría qué proporción de muestras sanas se clasifican correctamente como sanas. Esta métrica es relevante porque un modelo con baja especificidad generaría muchos falsos positivos, es decir, clasificaría como tumorales muestras que realmente no lo son. Por tanto, sensibilidad y especificidad deben interpretarse de forma conjunta, ya que reflejan errores de distinto tipo [22].

$$\frac{TN}{FP+TN}$$

La tasa de falsos positivos representa cuando el modelo clasifica como positiva una muestra que realmente pertenece a la clase negativa. Si se considera como clase positiva el cáncer de mama, un falso positivo corresponde a una muestra sana clasificada erróneamente como tumoral. Este tipo de error es importante porque puede llevar a interpretar como sospechosa una muestra que no presenta cáncer, lo que en un contexto clínico podría derivar en pruebas adicionales o preocupación innecesaria [22].

$$\frac{FP}{FP+TN}$$

A su vez, la tasa de falsos negativos indica que el modelo clasifica como negativa una muestra que realmente pertenece a la clase positiva. Un falso negativo corresponde a una muestra de cáncer de mama clasificada erróneamente como sana [22].

$$\frac{FN}{FN+TP}$$

Otra métrica habitual es la precisión, que indica qué proporción de las muestras clasificadas como positivas son realmente positivas. En otras palabras, si el modelo predice que varias muestras son tumorales, la precisión permite saber cuántas de esas predicciones son correctas. Esta métrica es útil cuando se quiere valorar la fiabilidad de las predicciones positivas del modelo [22].

$$\frac{TP}{TP+FP} * 100$$

F1-score resume precisión y sensibilidad en un único valor, lo cual resulta útil cuando interesa equilibrar la detección de positivos con la fiabilidad de esas predicciones [22].

$$2 * \frac{\text{sensibilidad} * \text{precisión}}{\text{sensibilidad} + \text{precisión}}$$

Además de las métricas anteriores, es frecuente utilizar la curva ROC y el área bajo dicha curva, conocida como (AUROC). La curva ROC representa el comportamiento del modelo al variar el umbral de decisión, comparando la sensibilidad frente a la tasa de falsos positivos. El valor AUC resume la capacidad general del modelo para separar las clases: cuanto más alto sea, mayor será la capacidad de discriminación entre muestras sanas y tumorales. Esta métrica se utiliza con frecuencia en estudios diagnósticos y de clasificación biomédica [16].

En algunos casos también puede ser útil analizar la curva precision-recall (PRC) y su área bajo la curva (AUPRC), especialmente cuando existe desequilibrio entre clases. Mientras que la curva ROC evalúa el equilibrio entre sensibilidad y falsos positivos, la curva precision-recall se centra en la relación entre sensibilidad y precisión, como su nombre indica. En estudios de metilación aplicados a clasificación tumoral se han usado tanto AUROC como AUPRC junto con otras métricas para comparar distintos algoritmos [16].

La forma de dividir los datos influye directamente en la fiabilidad de la evaluación. Una opción sencilla consiste en separar el conjunto de datos en dos partes: un conjunto de entrenamiento, utilizado para ajustar el modelo, y un conjunto de prueba, reservado para evaluar su rendimiento sobre muestras no utilizadas durante el aprendizaje. Sin embargo, cuando el número de muestras es reducido, una única división puede dar resultados

110 poco estables, ya que el rendimiento dependerá mucho de qué muestras hayan quedado en cada grupo. En estos casos puede utilizarse validación cruzada, que repite el proceso de entrenamiento y evaluación sobre distintas particiones del conjunto de datos. De esta forma se obtiene una estimación más robusta del comportamiento del modelo ante datos no vistos. Ante todo, se debe evitar cualquier fuga de información entre entrenamiento y prueba. Esto significa que pasos como la normalización, la selección de características o el ajuste de parámetros deben realizarse utilizando únicamente la información disponible en el conjunto de entrenamiento dentro de cada partición. Si se utilizan datos del conjunto de prueba durante estas fases, el rendimiento obtenido puede ser artificialmente alto y no reflejar la capacidad real de generalización del modelo [23].

55 Una evaluación adecuada de los modelos no debe basarse únicamente en la tasa de acierto. Resulta especialmente importante conocer qué tipo de errores comete el clasificador, ya que no tiene la misma implicación clasificar una muestra sana como tumoral que no detectar una muestra tumoral. Por ello, combinar distintas métricas permiten valorar el rendimiento del modelo de forma más completa y fiable.

2.4.7 Interpretabilidad de los modelos

13 En el análisis de perfiles de metilación, la interpretabilidad del modelo es un aspecto especialmente importante. No basta con que un algoritmo clasifique correctamente una muestra como sana o tumoral; también resulta relevante conocer qué variables han contribuido a esa decisión. Esto es especialmente útil en biomedicina, ya que las posiciones CpG más influyentes pueden orientar el análisis hacia genes o regiones reguladoras potencialmente relacionadas con el cáncer. Las revisiones sobre metilación y aprendizaje automático destacan que estos modelos no solo se emplean para clasificar muestras, sino también para apoyar la identificación de marcadores moleculares con posible utilidad diagnóstica o pronóstica [24].

Interpretar una variable relevante implica ir más allá del valor numérico del modelo. Como se ha mencionado en las características de los datos, una posición CpG seleccionada puede localizarse en el cuerpo de un gen, en una isla CpG o en una región reguladora. Por ello, después de identificar CpGs relevantes, suele ser necesario relacionarlas con su localización genómica y con los genes próximos. Este paso permite pasar de una interpretación puramente computacional a una interpretación biológica, analizando si las regiones destacadas por el modelo podrían estar relacionadas con procesos tumorales.

Una primera forma de interpretar un modelo consiste en analizar qué variables han tenido mayor influencia en la clasificación. En el caso de los perfiles de metilación, estas variables suelen corresponder a posiciones CpG. Algunos modelos ofrecen esta información de forma relativamente directa: por ejemplo, en la regresión logística pueden analizarse los coeficientes asignados a cada variable, mientras que en modelos basados en árboles puede analizarse qué variables han contribuido más a separar las clases. Aunque estas aproximaciones no explican por sí solas la función biológica de cada CpG, permiten identificar un primer conjunto de variables relevantes para el modelo.

58 También existen métodos específicos de explicación de modelos, como SHAP (SHapley Additive exPlanations). Este método estima la contribución de cada variable a la predicción del modelo, permitiendo analizar si una característica ha empujado la decisión hacia una clase u otra. En perfiles de metilación, SHAP puede utilizarse para analizar qué posiciones CpG contribuyen más a clasificar una muestra como tumoral o como sana. Su interés principal es que puede aplicarse a modelos complejos y permite estudiar tanto la importancia global de las variables como la explicación de predicciones individuales [25].

La interpretabilidad también es relevante en modelos de aprendizaje profundo, que como ya se ha mencionado, las decisiones suelen ser más difíciles de explicar que en modelos clásicos. En estos casos, pueden utilizarse técnicas de reducción de dimensionalidad, análisis de representaciones internas o métodos de atribución de variables para estudiar qué información está utilizando el modelo.

Aun así, la interpretación de un modelo debe realizarse con cuidado. Que una posición CpG aparezca como importante no significa necesariamente que sea la causa directa del cáncer o de la evolución clínica del paciente. Puede tratarse de una señal asociada al estado tumoral, a un subtipo concreto, al tejido de origen o incluso a factores técnicos si el preprocesamiento no ha sido adecuado. Por ello, las variables destacadas por el modelo deben entenderse como candidatas de interés, que posteriormente requieren análisis biológico, validación externa y comparación con conocimiento previo.

De esta forma, la interpretabilidad permite que los modelos de clasificación no funcionen únicamente como sistemas de predicción, sino también como herramientas de análisis molecular. En perfiles de metilación, identificar CpGs, genes o regiones reguladoras relevantes puede ayudar a comprender mejor las diferencias entre muestras sanas y tumorales, proponer posibles biomarcadores y generar hipótesis biológicas que complementen los resultados computacionales.

3 Resultados y conclusiones

3.1 Conjuntos de datos y metodología

8

Para la parte experimental de este trabajo se utilizó un conjunto de datos de metilación del ADN correspondiente al cáncer de mama, procedente del proyecto TCGA-BRCA [26]. Este conjunto contiene perfiles de metilación obtenidos mediante la plataforma Illumina HumanMethylation450, donde cada posición CpG se representa mediante un valor beta, como se explicó anteriormente .

El conjunto original contenía 486.428 posiciones CpG y 893 muestras. Para plantear el problema como una tarea de clasificación binaria, se seleccionaron únicamente las muestras correspondientes a tejido tumoral primario y tejido normal sólido, identificadas en TCGA mediante los códigos 01 y 11, respectivamente. Tras este filtrado, el conjunto quedó formado por 888 muestras: 791 muestras tumorales primarias y 97 muestras normales. Las 5 muestras restantes correspondían a muestras metastásicas, identificadas mediante el código 06, por lo que no se incluyeron en el análisis al no pertenecer a ninguna de las dos clases definidas para este experimento.

Tras este filtrado, el conjunto presentaba un claro desbalance entre clases, con muchas más muestras tumorales que normales. Para evitar que los modelos aprendieran sesgos derivados de este desbalance, se generó un conjunto de datos balanceado. Para ello, se conservaron todas las muestras normales disponibles y se seleccionó aleatoriamente el mismo número de muestras tumorales. De esta forma, el conjunto final utilizado quedó formado por 194 muestras: 97 tumorales y 97 normales.

Dado que el número original de posiciones CpG era muy elevado en comparación con el número de muestras, se realizó una reducción de dimensionalidad. Primero se descartaron las posiciones CpG con demasiados valores ausentes, conservando únicamente aquellas con valores válidos en al menos el 80 % de las muestras seleccionadas. A continuación, se seleccionaron las 1000 posiciones CpG con mayor varianza entre las muestras, ya que las posiciones con variación muy baja aportan poca información para distinguir entre clases.

Antes de entrenar los modelos, los valores ausentes fueron tratados mediante imputación, sustituyéndolos por la mediana correspondiente de cada posición CpG. Esta estrategia permitió conservar las muestras y atributos seleccionados sin introducir valores extremos artificiales. El conjunto final

utilizado en los experimentos estuvo compuesto por 194 instancias y 1001 atributos. Este quedó organizado en formato ARFF, con las muestras como filas, las posiciones CpG como atributos y una variable de clase final indicando si cada muestra correspondía a tejido tumoral o normal [27].

Además del conjunto utilizado para la clasificación entre muestras tumorales y normales, se construyó un segundo conjunto orientado al análisis exploratorio de la evolución clínica de los pacientes. Para ello, se combinaron los perfiles de metilación con la información clínica disponible en TCGA-BRCA. En este caso, se utilizaron únicamente muestras tumorales primarias, ya que el objetivo era estudiar la evolución de pacientes oncológicos y no la diferenciación entre tejido tumoral y tejido normal.

La información clínica se empleó para definir una variable binaria de supervivencia a 5 años. Se consideró como mala evolución el fallecimiento antes de los 5 años, mientras que se consideró como buena evolución alcanzar al menos 5 años de seguimiento o supervivencia. Los pacientes vivos con un seguimiento inferior a 5 años no se incluyeron en este análisis, ya que no era posible determinar con seguridad si alcanzarían o no dicho umbral temporal. Tras aplicar este criterio, el conjunto quedó formado por 253 pacientes, de los cuales 179 correspondían a buena evolución y 74 a mala evolución.

En este segundo experimento, las variables clínicas no se utilizaron como atributos predictivos, sino únicamente para construir la etiqueta de evolución clínica de cada paciente. Los atributos de entrada siguieron siendo los valores beta de metilación de las posiciones CpG. Al igual que en el primer experimento, se descartaron las CpGs con demasiados valores ausentes, se seleccionaron las 1000 posiciones con mayor varianza entre las muestras incluidas y los valores ausentes restantes se imputaron mediante la mediana de cada CpG. El conjunto final para este análisis quedó organizado en formato ARFF, con 253 instancias y 1001 atributos, correspondientes a 1000 posiciones CpG y una variable de clase final indicando buena o mala evolución.

Los modelos se evaluaron utilizando el entorno Weka, concretamente la versión 3.8.6. Esta herramienta es ampliamente empleada para aplicar algoritmos de aprendizaje automático de forma visual y reproducible [28]. Por último, en ambos experimentos los modelos se evaluaron mediante validación cruzada estratificada de 10 particiones. En este procedimiento, el conjunto de datos se divide en diez partes, manteniendo la proporción de clases en cada partición.

3.2 Análisis de clasificación tumoral

Tabla 2. Matriz de confusión para regresión logística

Clase predicha / Clase real	Tumor	Normal
Tumor	95 (TP)	1 (FP)
Normal	2 (FN)	96 (TN)

Tabla 3. Métricas para regresión logística

Tasa de acierto	Sensibilidad	Especificidad	Tasa de FP	Tasa de FN	Precisión	F1-score	AUROC	AUPRC
98,45 %	0,979	0,99	0,01	0,021	0,99	0,984	0,989	0,994

La regresión logística obtuvo una tasa de acierto del 98,45 %, clasificando correctamente 191 de las 194 muestras evaluadas. A partir de la matriz de confusión se observa que el modelo identificó correctamente 95 muestras tumorales y 96 muestras normales, cometiendo únicamente tres errores: una muestra normal fue clasificada como tumoral y dos muestras tumorales fueron clasificadas como normales.

Considerando la clase tumoral como clase positiva, la sensibilidad fue de 0,979, lo que indica que el modelo detectó correctamente 95 de las 97 muestras tumorales. La especificidad fue de 0,99, por lo que también reconoció adecuadamente 96 de las 97 muestras normales. Estos valores se corresponden con una tasa de falsos negativos de 0,021 y una tasa de falsos positivos de 0,01.

La precisión alcanzó un valor de 0,99, lo que significa que casi todas las muestras clasificadas por el modelo como tumorales eran realmente tumorales. Además, la puntuación F1 fue de 0,984, reflejando un buen equilibrio entre la capacidad para detectar tumores y la fiabilidad de las predicciones positivas. Por último, los valores de AUROC y AUPRC fueron 0,989 y 0,994 respectivamente, lo que indica una elevada capacidad de

discriminación entre muestras tumorales y normales. Estos resultados muestran que la regresión logística obtuvo un rendimiento muy alto sobre el conjunto de datos balanceado.

A partir de los coeficientes obtenidos por la regresión logística, se identificaron las posiciones CpG con mayor peso en la clasificación. Dado que Weka muestra los coeficientes respecto a la clase normal, los coeficientes positivos indican una mayor contribución hacia la clasificación como muestra normal, mientras que los coeficientes negativos desplazan la predicción hacia la clase tumoral. Por tanto, las posiciones CpG con mayor valor absoluto pueden considerarse las variables con mayor influencia dentro del modelo.

Entre las posiciones más asociadas a la clasificación como tumor destacaron cg11717189 y cg21577651, con coeficientes negativos de gran magnitud. Por el contrario, posiciones como cg19585676, cg19486070 y cg00467244 presentaron coeficientes positivos elevados, por lo que contribuyeron en mayor medida a la clasificación como muestra normal.

Aunque el modelo incluye regularización ridge, el valor del parámetro por defecto utilizado fue muy pequeño, por lo que su efecto sobre los coeficientes puede considerarse limitado.

Tabla 4. Matriz de confusión para SVM

Clase predicha / Clase real	Tumor	Normal
Tumor	96 (TP)	0 (FP)
Normal	1 (FN)	97 (TN)

Tabla 5. Métricas para SVM

Tasa de acierto	Sensibilidad	Especificidad	Tasa de FP	Tasa de FN	Precisión	F1-score	AUROC	AUPRC
99,48 %	0,99	1	0	0,01	1	0,995	0,995	0,995

El modelo SVM obtuvo una tasa de acierto del 99,48 %, clasificando correctamente 193 de las 194 muestras evaluadas. A partir de la matriz de confusión se observa que identificó correctamente 96 muestras tumorales y 97 muestras normales, cometiendo únicamente un error.

Considerando la clase tumoral como clase positiva, la sensibilidad fue de 0,99, lo que indica que el modelo detectó correctamente 96 de las 97 muestras tumorales. La especificidad fue de 1, por lo que todas las muestras normales fueron reconocidas correctamente. Estos resultados se corresponden con una tasa de falsos negativos de 0,01 y una tasa de falsos positivos de 0.

La precisión alcanzó un valor de 1, lo que significa que todas las muestras clasificadas como tumorales eran realmente tumorales. Además, la puntuación F1 fue de 0,995, reflejando un equilibrio muy alto entre precisión y sensibilidad. Por último, los valores de AUROC y AUPRC fueron ambos de 0,995, lo que indica una elevada capacidad del modelo para diferenciar entre muestras tumorales y normales.

En el modelo SVM, Weka proporciona los pesos normalizados asignados a cada posición CpG. Las posiciones con mayor valor absoluto del peso pueden considerarse las más influyentes en la clasificación.

En este modelo, las posiciones cg06946452 y cg11717189 presentaron los mayores pesos positivos, por lo que contribuyeron de forma destacada a la clasificación como muestra tumoral. Por el contrario, cg12662576 y cg10327440 presentaron los pesos negativos de mayor magnitud, asociándose con la clasificación como muestra normal.

Tabla 6. Matriz de confusión para Random Forest

Clase predicha / Clase real	Tumor	Normal
Tumor	95 (TP)	2 (FP)
Normal	2 (FN)	95 (TN)

Tabla 7. Métricas para Random Forest

Tasa de acierto	Sensibilidad	Especificidad	Tasa de FP	Tasa de FN	Precisión	F1-score	AUROC	AUPRC
97,94 %	0,979	0,979	0,021	0,021	0,979	0,979	0,991	0,995

El modelo Random Forest obtuvo una tasa de acierto del 97,94 %, clasificando correctamente 190 de las 194 muestras evaluadas. A partir de la matriz de confusión se observa que el modelo identificó correctamente 95 muestras tumorales y 95 muestras normales, cometiendo un total de cuatro errores.

Considerando la clase tumoral como clase positiva, la sensibilidad fue de 0,979, lo que indica que el modelo detectó correctamente 95 de las 97 muestras tumorales. La especificidad también fue de 0,979, por lo que reconoció correctamente 95 de las 97 muestras normales. Estos resultados se corresponden con una tasa de falsos negativos de 0,021 y una tasa de falsos positivos de 0,021.

La precisión alcanzó un valor de 0,979, lo que indica que la mayoría de las muestras clasificadas como tumorales eran realmente tumorales. La puntuación F1 fue también de 0,979. Por último, los valores de AUROC y AUPRC fueron de 0,991 y 0,995 respectivamente, mostrando que el modelo mantiene una elevada capacidad para diferenciar entre muestras tumorales y normales.

En el caso de Random Forest, la importancia de las variables se obtuvo a partir de la mejora media que produce cada variable al separar las clases dentro de los árboles. A diferencia de la regresión logística o de una SVM, esta importancia no proporciona directamente una dirección hacia la clase tumoral o normal, sino una medida global de relevancia para la clasificación.

Las posiciones CpG con mayor importancia fueron cg14118515, cg07519235, cg02907150, cg23091104 y cg27363327, todas ellas con un valor de importancia de 1. Este valor de importancia se muestra normalizado en un intervalo entre 0 y 1. Las posiciones CpG con valores más cercanos a 1 son las que más contribuyen a mejorar la separación entre muestras tumorales y normales dentro de los árboles del modelo. Además, destacaron cg13305186, cg14861089, cg17239236, cg17402060 y cg01268824, con valores superiores a 0,95.

Tabla 8. Matriz de confusión para Naive Bayes

Clase predicha / Clase real	Tumor	Normal
Tumor	96 (TP)	7 (FP)
Normal	0 (FN)	4 (TN)
Sin clasificar	1	86

Tabla 9. Métricas para Naive Bayes

Tasa de acierto	Sensibilidad	Especificidad	Tasa de FP	Tasa de FN	Precisión	F1-score	AUROC	AUPRC
51,55 %	1	0,364	0,636	0	0,932	0,965	0,959	0,928

El modelo Naive Bayes obtuvo una tasa de acierto del 51,55 %, clasificando correctamente 100 de las 194 muestras evaluadas. El resultado se debe a que el modelo dejó sin clasificar 87 muestras, lo que representa el 44,85 % del conjunto de datos.

A partir de la matriz de confusión se observa que el modelo identificó correctamente 96 muestras tumorales y 4 muestras normales. Además, clasificó erróneamente 7 muestras normales como tumorales. El aspecto más relevante es que 86 muestras normales y 1 muestra tumoral quedaron sin clasificar, por lo que el modelo mostró una clara dificultad para asignar una clase a gran parte de las muestras normales.

Considerando la clase tumoral como clase positiva, tenemos una sensibilidad de 1 y una precisión de 0,932. No obstante, estos valores no reflejan adecuadamente el elevado número de muestras sin clasificar. La especificidad fue de 0,364, lo que indica una baja capacidad del modelo para reconocer correctamente las muestras normales que sí recibieron una predicción.

En conjunto, Naive Bayes no resultó adecuado para este conjunto de datos. Aunque clasificó correctamente la mayoría de las muestras tumorales que recibieron una predicción, el elevado porcentaje de instancias sin clasificar limita claramente su utilidad en este problema. Este comportamiento se puede deber a que el modelo puede no adaptarse bien a perfiles de metilación, al

trabajar con muchas variables numéricas continuas, pocas muestras y una fuerte suposición de independencia entre atributos.

Tabla 10. Matriz de confusión para Naive Bayes con discretización supervisada

Clase predicha / Clase real	Tumor	Normal
Tumor	95 (TP)	3 (FP)
Normal	2 (FN)	94 (TN)

Tabla 11. Métricas para Naive Bayes con discretización supervisada

Tasa de acierto	Sensibilidad	Especificidad	Tasa de FP	Tasa de FN	Precisión	F1-score	AUROC	AUPRC
97,42 %	0,979	0,969	0,031	0,021	0,969	0,974	0,979	0,964

En este caso se aplicó discretización supervisada al modelo Naive Bayes. Esta técnica transforma los valores continuos de metilación en intervalos definidos teniendo en cuenta la clase de las muestras. Con ello se facilita la estimación de probabilidades por parte del modelo y se reduce la dependencia de la suposición de que las variables numéricas siguen una distribución normal. Esta modificación se aplicó porque el modelo Naive Bayes original dejó un número elevado de instancias sin clasificar.

El modelo Naive Bayes con discretización supervisada obtuvo una tasa de acierto del 97,42 %, clasificando correctamente 189 de las 194 muestras evaluadas. A partir de la matriz de confusión se observa que el modelo identificó correctamente 95 muestras tumorales y 94 muestras normales, cometiendo un total de cinco errores.

3

Considerando la clase tumoral como clase positiva, la sensibilidad fue de 0,979, lo que indica que el modelo detectó correctamente 95 de las 97 muestras tumorales. La especificidad fue de 0,969, por lo que reconoció correctamente 94 de las 97 muestras normales. Estos resultados se corresponden con una tasa de falsos negativos de 0,021 y una tasa de falsos positivos de 0,031.

1

La precisión alcanzó un valor de 0,969, lo que indica que la mayoría de las muestras clasificadas como tumorales eran realmente tumorales. La puntuación F1 fue de 0,974, mientras que los valores de AUROC y AUPRC fueron 0,979 y 0,964.

Tabla 12. Matriz de confusión para J48

Clase predicha / Clase real	Tumor	Normal
Tumor	92 (TP)	5 (FP)
Normal	5 (FN)	92 (TN)

Tabla 13. Métricas para J48

Tasa de acierto	Sensibilidad	Especificidad	Tasa de FP	Tasa de FN	Precisión	F1-score	AUROC	AUPRC
94,85 %	0,948	0,948	0,052	0,052	0,948	0,948	0,956	0,94

El modelo J48, correspondiente a un árbol de decisión, obtuvo una tasa de acierto del 94,85 %, clasificando correctamente 184 de las 194 muestras evaluadas. A partir de la matriz de confusión se observa que el modelo identificó correctamente 92 muestras tumorales y 92 muestras normales, cometiendo un total de diez errores: cinco muestras normales fueron clasificadas como tumorales y cinco muestras tumorales fueron clasificadas como normales.

1

3 Considerando la clase tumoral como clase positiva, la sensibilidad fue de 0,948, lo que indica que el modelo detectó correctamente 92 de las 97 muestras tumorales. La especificidad también fue de 0,948, por lo que reconoció correctamente 92 de las 97 muestras normales. Estos resultados se corresponden con una tasa de falsos negativos de 0,052 y una tasa de falsos positivos de 0,052.

1 La precisión alcanzó un valor de 0,948, lo que indica que la mayoría de las muestras clasificadas como tumorales eran realmente tumorales. La puntuación F1 fue también de 0,948. Por último, los valores de AUROC y AUPRC fueron 0,956 y 0,94, respectivamente, mostrando una buena capacidad del modelo para diferenciar entre muestras tumorales y normales.

2 Además, el árbol generado fue relativamente simple, con 4 hojas y un tamaño total de 7 nodos, lo que facilita su interpretación en comparación con modelos más complejos como Random Forest.

Las posiciones CpG más relevantes fueron cg27170427, cg17415451 y cg07129523, ya que fueron las únicas variables utilizadas por el árbol de decisión para separar las muestras tumorales y normales. La posición cg27170427 fue la más importante, al aparecer en la raíz del árbol, es decir, como primera condición de separación. En este modelo, las muestras con valores de metilación en cg27170427 iguales o inferiores a 0,755544 fueron clasificadas directamente como tumorales. Para el resto de muestras, el árbol utilizó posteriormente cg17415451 y cg07129523 para completar la clasificación. A diferencia de Random Forest, J48 no proporciona un valor numérico normalizado de importancia para cada variable, sino que la relevancia se interpreta a partir de la posición que ocupa cada CpG dentro del árbol, siendo las variables situadas en los niveles superiores las que tienen mayor influencia en la decisión del modelo.

Tabla 14. Matriz de confusión para knn (K = 1)

Clase predicha / Clase real	Tumor	Normal
Tumor	86 (TP)	1 (FP)
Normal	11 (FN)	96 (TN)

Tabla 15. Métricas para knn (K = 1)

Tasa de acierto	Sensibilidad	Especificidad	Tasa de FP	Tasa de FN	Precisión	F1-score	AUROC	AUPRC
93,81 %	0,887	0,99	0,01	0,113	0,989	0,935	0,938	0,939

Tabla 16. Matriz de confusión para knn (K = 3)

Clase predicha / Clase real	Tumor	Normal
Tumor	89 (TP)	0 (FP)
Normal	8 (FN)	97 (TN)

Tabla 17. Métricas para knn (K = 3)

Tasa de acierto	Sensibilidad	Especificidad	Tasa de FP	Tasa de FN	Precisión	F1-score	AUROC	AUPRC
95,88 %	0,918	1	0	0,082	1	0,957	0,982	0,985

Tabla 18. Matriz de confusión para knn (K = 5)

Clase predicha / Clase real	Tumor	Normal
Tumor	91 (TP)	0 (FP)
Normal	6 (FN)	97 (TN)

Tabla 19. Métricas para knn (K = 5)

Tasa de acierto	Sensibilidad	Especificidad	Tasa de FP	Tasa de FN	Precisión	F1-score	AUROC	AUPRC
96,91 %	0,938	1	0	0,062	1	0,968	0,984	0,988

El modelo k-nearest neighbors, clasifica cada muestra en función de las k muestras más cercanas. En este trabajo se evaluaron tres configuraciones diferentes, con K=1, K=3 y K=5, con el objetivo de analizar cómo influye el número de vecinos considerados en el rendimiento del modelo.

Con K=1, el modelo obtuvo una tasa de acierto del 93,81 %, clasificando correctamente 182 de las 194 muestras evaluadas. A partir de la matriz de confusión se observa que identificó correctamente 86 muestras tumorales y 96 muestras normales, cometiendo un total de doce errores: una muestra normal fue clasificada como tumoral y once muestras tumorales fueron clasificadas como normales. Considerando la clase tumoral como clase positiva, la sensibilidad fue de 0,887, lo que indica que el modelo detectó correctamente 86 de las 97 muestras tumorales. La especificidad fue de 0,99, por lo que reconoció correctamente 96 de las 97 muestras normales. Estos resultados se corresponden con una tasa de falsos negativos de 0,113 y una tasa de falsos positivos de 0,01. La precisión fue de 0,989, lo que indica que casi todas las muestras clasificadas como tumorales eran realmente tumorales. La puntuación F1 fue de 0,935, mientras que los valores de AUROC y AUPRC fueron 0,938 y 0,939 respectivamente.

Con K=3, el rendimiento mejoró, alcanzando una tasa de acierto del 95,88 %, con 186 muestras correctamente clasificadas. En este caso, el modelo identificó correctamente 89 muestras tumorales y 97 muestras normales. Los ocho errores cometidos corresponden a muestras tumorales clasificadas como normales, sin producir falsos positivos. Considerando la clase tumoral como positiva, la sensibilidad fue de 0,918, lo que refleja una mejora en la detección de muestras tumorales respecto a K=1. La especificidad fue de 1, ya que todas las muestras normales fueron clasificadas correctamente. Estos resultados se corresponden con una tasa de falsos negativos de 0,082 y una tasa de falsos positivos de 0. La precisión alcanzó un valor de 1, lo que indica que todas las muestras clasificadas como tumorales eran realmente tumorales. La puntuación F1 alcanzó 0,957 y los valores de AUROC y AUPRC fueron 0,982 y 0,985 respectivamente.

Con $K=5$, el modelo obtuvo el mejor resultado entre las configuraciones evaluadas, con una tasa de acierto del 96,91 % y 188 muestras correctamente clasificadas. La matriz de confusión muestra que identificó correctamente 91 muestras tumorales y 97 muestras normales, cometiendo únicamente seis errores, todos ellos correspondientes a muestras tumorales clasificadas como normales. Considerando la clase tumoral como positiva, la sensibilidad fue de 0,938, por lo que el modelo detectó correctamente 91 de las 97 muestras tumorales. La especificidad fue de 1, ya que no clasificó ninguna muestra normal como tumoral. Estos resultados se corresponden con una tasa de falsos negativos de 0,062 y una tasa de falsos positivos de 0. La precisión fue de 1, la puntuación F1 alcanzó 0,968, mientras que los valores de AUROC y AUPRC fueron 0,984 y 0,988 respectivamente.

En conjunto, el aumento del número de vecinos mejoró progresivamente el rendimiento del modelo. La configuración con $K = 5$ fue la más adecuada entre las tres evaluadas, ya que obtuvo la mayor tasa de acierto, redujo el número de falsos negativos y mantuvo una especificidad perfecta. Aun así, el modelo siguió clasificando algunas muestras tumorales como normales, por lo que su sensibilidad fue inferior a la obtenida por algunos de los modelos evaluados previamente.

Tabla 20. Matriz de confusión para AdaBoostM1

Clase predicha / Clase real	Tumor	Normal
Tumor	96 (TP)	1 (FP)
Normal	1 (FN)	96 (TN)

Tabla 21. Métricas para AdaBoostM1

Tasa de acierto	Sensibilidad	Especificidad	Tasa de FP	Tasa de FN	Precisión	F1-score	AUROC	AUPRC
98,97 %	0,99	0,99	0,01	0,01	0,99	0,99	0,985	0,985

El modelo AdaBoostM1 es un método basado en boosting que combina varios clasificadores débiles para construir un clasificador más robusto. En este caso, se utilizó como clasificador base DecisionStump, un árbol de decisión simple de una sola división. AdaBoost entrena los clasificadores de forma iterativa, prestando mayor atención a las muestras que han sido clasificadas incorrectamente en iteraciones anteriores.

El modelo AdaBoostM1 obtuvo una tasa de acierto del 98,97 %, clasificando correctamente 192 de las 194 muestras evaluadas. A partir de la matriz de confusión se observa que el modelo identificó correctamente 96 muestras tumorales y 96 muestras normales, cometiendo únicamente dos errores.

Considerando la clase tumoral como clase positiva, la sensibilidad fue de 0,99, lo que indica que el modelo detectó correctamente 96 de las 97 muestras tumorales. La especificidad también fue de 0,99, por lo que reconoció correctamente 96 de las 97 muestras normales. Estos resultados se corresponden con una tasa de falsos negativos y una tasa de falsos positivos de 0,01.

La precisión alcanzó un valor de 0,99, lo que indica que casi todas las muestras clasificadas como tumorales eran realmente tumorales. La puntuación F1 fue también de 0,99. Por último, los valores de AUROC y AUPRC fueron 0,985 y 0,985, respectivamente.

Tabla 22. Matriz de confusión para MLP

Clase predicha / Clase real	Tumor	Normal
Tumor	95 (TP)	0 (FP)
Normal	2 (FN)	97 (TN)

Tabla 23. Métricas para MLP

Tasa de acierto	Sensibilidad	Especificidad	Tasa de FP	Tasa de FN	Precisión	F1-score	AUROC	AUPRC
98,97 %	0,979	1	0	0,021	1	0,99	0,996	0,997

El modelo MLP obtuvo una tasa de acierto del 98,97 %, clasificando correctamente 192 de las 194 muestras evaluadas. A partir de la matriz de confusión se observa que el modelo identificó correctamente 95 muestras tumorales y 97 muestras normales, cometiendo únicamente dos errores.

Considerando la clase tumoral como clase positiva, la sensibilidad fue de 0,979, lo que indica que el modelo detectó correctamente 95 de las 97 muestras tumorales. La especificidad fue de 1, por lo que todas las muestras normales fueron reconocidas correctamente. Estos resultados se corresponden con una tasa de falsos negativos de 0,021 y una tasa de falsos positivos de 0.

La precisión alcanzó un valor de 1, lo que significa que todas las muestras clasificadas como tumorales eran realmente tumorales. La puntuación F1 fue de 0,99, lo que muestra un equilibrio muy alto entre precisión y sensibilidad. Por último, los valores de AUROC y AUPRC fueron 0,996 y 0,997 respectivamente, demostrando el modelo una elevada capacidad para diferenciar entre muestras tumorales y normales.

Aunque el rendimiento obtenido fue muy alto, el tiempo de entrenamiento fue superior al de los modelos anteriores. Esto refleja el mayor coste computacional asociado a las redes neuronales, especialmente en conjuntos de datos con un número elevado de variables, como ocurre con los perfiles de metilación.

Tabla 24. Matriz de confusión para autoencoder

Clase predicha / Clase real	Tumor	Normal
Tumor	93 (TP)	1 (FP)
Normal	4 (FN)	96 (TN)

Tabla 25. Métricas para autoencoder

Tasa de acierto	Sensibilidad	Especificidad	Tasa de FP	Tasa de FN	Precisión	F1-score	AUROC	AUPRC
97,42 %	0,959	0,99	0,01	0,041	0,989	0,974	0,982	0,988

En este experimento se evaluó un enfoque basado en autoencoder. El autoencoder se utilizó como método de reducción de dimensionalidad, transformando las posiciones CpG originales en una representación comprimida de 5 variables. Posteriormente, esta representación se empleó como entrada de un modelo MLP para clasificar las muestras como tumorales o normales. El procedimiento se realizó mediante FilteredClassifier, de forma que la transformación del autoencoder se aplicó dentro de cada partición de la validación cruzada, evitando fuga de información entre entrenamiento y evaluación.

El modelo autoencoder obtuvo una tasa de acierto del 97,42 %, clasificando correctamente 189 de las 194 muestras evaluadas. A partir de la matriz de confusión se observa que el modelo identificó correctamente 93 muestras tumorales y 96 muestras normales, cometiendo un total de cinco errores.

Considerando la clase tumoral como clase positiva, la sensibilidad fue de 0,959, lo que indica que el modelo detectó correctamente 93 de las 97 muestras tumorales. La especificidad fue de 0,99, por lo que reconoció correctamente 96 de las 97 muestras normales. Estos resultados se corresponden con una tasa de falsos negativos de 0,041 y una tasa de falsos positivos de 0,01.

La precisión alcanzó un valor de 0,989, lo que indica que casi todas las muestras clasificadas como tumorales eran realmente tumorales. La puntuación F1 fue de 0,974, mientras que los valores de AUROC y AUPRC fueron 0,982 y 0,988 respectivamente.

Como interpretación general, el autoencoder permitió reducir de forma notable la dimensionalidad del conjunto de datos, pasando de 1000 posiciones CpG a solo 5 variables latentes. Aun así, el modelo mantuvo un rendimiento elevado, aunque clasificó cuatro muestras tumorales como normales, por lo que su sensibilidad fue algo inferior a la de otros modelos evaluados previamente.

3.3 Análisis de evolución de los pacientes

En las siguientes tablas se muestran los resultados obtenidos para la predicción exploratoria de la evolución clínica a 5 años. En todos los modelos se considera la clase de mala evolución como clase positiva. Por tanto, la sensibilidad indica la capacidad del modelo para detectar correctamente a los pacientes con mala evolución, mientras que la especificidad indica la capacidad para reconocer correctamente a los pacientes con buena evolución.

39

Tabla 26. Matriz de confusión para Regresión logística

Clase predicha / Clase real	Mala evolución	Buena evolución
Mala evolución	26 (TP)	51 (FP)
Buena evolución	48 (FN)	128 (TN)

Tabla 27. Métricas para Regresión logística

Tasa de acierto	Sensibilidad	Especificidad	Tasa de FP	Tasa de FN	Precisión	F1-score	AUROC	AUPRC
60,87 %	0,351	0,715	0,285	0,649	0,338	0,344	0,521	0,313

La regresión logística obtuvo una tasa de acierto del 60,87 %, clasificando correctamente 154 de las 253 muestras evaluadas. A partir de la matriz de confusión se observa que el modelo identificó correctamente 26 pacientes con mala evolución y 128 pacientes con buena evolución, cometiendo un total de 99 errores.

Considerando la clase mala evolución como clase positiva, la sensibilidad fue de 0,351, lo que indica que el modelo detectó correctamente 26 de los 74 pacientes con mala evolución. La especificidad fue de 0,715, por lo que reconoció correctamente 128 de los 179 pacientes con buena evolución. Estos resultados se corresponden con una tasa de falsos negativos de 0,649 y una tasa de falsos positivos de 0,285.

La precisión alcanzó un valor de 0,338, lo que indica que solo una parte reducida de los pacientes clasificados como mala evolución pertenecían realmente a esa clase. La puntuación F1 fue de 0,344, mientras que los valores de AUROC y AUPRC fueron 0,521 y 0,313 respectivamente. Estos resultados muestran que, en este experimento, la regresión logística presentó una capacidad limitada para anticipar la evolución clínica a 5 años.

Tabla 28. Matriz de confusión para SVM

Clase predicha / Clase real	Mala evolución	Buena evolución
Mala evolución	30 (TP)	39 (FP)
Buena evolución	44 (FN)	140 (TN)

Tabla 29. Métricas para SVM

Tasa de acierto	Sensibilidad	Especificidad	Tasa de FP	Tasa de FN	Precisión	F1-score	AUROC	AUPRC
67,19 %	0,405	0,782	0,218	0,595	0,435	0,42	0,594	0,35

La SVM obtuvo una tasa de acierto del 67,19 %, clasificando correctamente 170 de las 253 muestras evaluadas. A partir de la matriz de confusión se observa que el modelo identificó correctamente 30 pacientes con mala evolución y 140 pacientes con buena evolución, cometiendo un total de 83 errores.

Considerando la clase mala evolución como clase positiva, la sensibilidad fue de 0,405, lo que indica que el modelo detectó correctamente 30 de los 74 pacientes con mala evolución. La especificidad fue de 0,782, por lo que reconoció correctamente 140 de los 179 pacientes con buena evolución. Estos resultados se corresponden con una tasa de falsos negativos de 0,595 y una tasa de falsos positivos de 0,218.

La precisión alcanzó un valor de 0,435, lo que indica que menos de la mitad de los pacientes clasificados como mala evolución pertenecían realmente a esa clase. La puntuación F1 fue de 0,42, mientras que los valores de AUROC y AUPRC fueron 0,594 y 0,35 respectivamente. Estos resultados muestran que la SVM obtuvo un rendimiento algo superior al de la regresión logística, aunque su capacidad para identificar correctamente a los pacientes con mala evolución siguió siendo limitada.

Tabla 30. Matriz de confusión para Random Forest

Clase predicha / Clase real	Mala evolución	Buena evolución
Mala evolución	3 (TP)	2 (FP)
Buena evolución	71 (FN)	177 (TN)

Tabla 31. Métricas para Random Forest

Tasa de acierto	Sensibilidad	Especificidad	Tasa de FP	Tasa de FN	Precisión	F1-score	AUROC	AUPRC
71,15 %	0,041	0,989	0,011	0,959	0,6	0,076	0,617	0,417

Random Forest obtuvo una tasa de acierto del 71,15 %, clasificando correctamente 180 de las 253 muestras evaluadas. A partir de la matriz de confusión se observa que el modelo identificó correctamente 3 pacientes con mala evolución y 177 pacientes con buena evolución, cometiendo un total de 73 errores.

Considerando la clase mala evolución como clase positiva, la sensibilidad fue de 0,041, lo que indica que el modelo detectó correctamente solo 3 de los 74 pacientes con mala evolución. La especificidad fue de 0,989, por lo que reconoció correctamente 177 de los 179 pacientes con buena evolución. Estos resultados se corresponden con una tasa de falsos negativos de 0,959 y una tasa de falsos positivos de 0,011.

La precisión alcanzó un valor de 0,6, lo que indica que más de la mitad de los pacientes clasificados como mala evolución pertenecían realmente a esa clase. Sin embargo, este valor debe interpretarse con cautela, ya que el modelo clasificó muy pocos pacientes como mala evolución. La puntuación F1 fue de 0,076, mientras que los valores de AUROC y AUPRC fueron 0,617 y 0,417 respectivamente. Estos resultados muestran que Random Forest tendió a clasificar la mayoría de los casos como buena evolución, por lo que no resultó adecuado para detectar pacientes con peor pronóstico.

Tabla 32. Matriz de confusión para Naive Bayes

Clase predicha / Clase real	Mala evolución	Buena evolución
Mala evolución	33 (TP)	54 (FP)
Buena evolución	41 (FN)	125 (TN)

Tabla 33. Métricas para Naive Bayes

Tasa de acierto	Sensibilidad	Especificidad	Tasa de FP	Tasa de FN	Precisión	F1-score	AUROC	AUPRC
62,45 %	0,446	0,698	0,302	0,554	0,379	0,41	0,571	0,33

Naive Bayes obtuvo una tasa de acierto del 62,45 %, clasificando correctamente 158 de las 253 muestras evaluadas. A partir de la matriz de confusión se observa que el modelo identificó correctamente 33 pacientes con mala evolución y 125 pacientes con buena evolución, cometiendo un total de 95 errores.

Considerando la clase mala evolución como clase positiva, la sensibilidad fue de 0,446, lo que indica que el modelo detectó correctamente 33 de los 74 pacientes con mala evolución. La especificidad fue de 0,698, por lo que reconoció correctamente 125 de los 179 pacientes con buena evolución. Estos resultados se corresponden con una tasa de falsos negativos de 0,554 y una tasa de falsos positivos de 0,302.

La precisión alcanzó un valor de 0,379, lo que indica que una proporción limitada de los pacientes clasificados como mala evolución pertenecían realmente a esa clase. La puntuación F1 fue de 0,41, mientras que los valores de AUROC y AUPRC fueron 0,571 y 0,33 respectivamente. Estos resultados muestran que Naive Bayes detectó una mayor proporción de pacientes con mala evolución que algunos modelos anteriores, aunque a costa de clasificar incorrectamente como mala evolución a un número elevado de pacientes con buena evolución.

Tabla 34. Matriz de confusión para J48

Clase predicha / Clase real	Mala evolución	Buena evolución
Mala evolución	27 (TP)	47 (FP)
Buena evolución	47 (FN)	132 (TN)

Tabla 35. Métricas para J48

Tasa de acierto	Sensibilidad	Especificidad	Tasa de FP	Tasa de FN	Precisión	F1-score	AUROC	AUPRC
62,85 %	0,365	0,737	0,263	0,635	0,365	0,365	0,533	0,316

El modelo J48 obtuvo una tasa de acierto del 62,85 %, clasificando correctamente 159 de las 253 muestras evaluadas. A partir de la matriz de confusión se observa que el modelo identificó correctamente 27 pacientes con mala evolución y 132 pacientes con buena evolución, cometiendo un total de 94 errores.

Considerando la clase mala evolución como clase positiva, la sensibilidad fue de 0,365, lo que indica que el modelo detectó correctamente 27 de los 74 pacientes con mala evolución. La especificidad fue de 0,737, por lo que reconoció correctamente 132 de los 179 pacientes con buena evolución. Estos resultados se corresponden con una tasa de falsos negativos de 0,635 y una tasa de falsos positivos de 0,263.

La precisión alcanzó un valor de 0,365, lo que indica que solo una parte de los pacientes clasificados como mala evolución pertenecían realmente a esa clase. La puntuación F1 fue de 0,365, mientras que los valores de AUROC y AUPRC fueron 0,533 y 0,316 respectivamente. Estos resultados muestran que J48 presentó una capacidad limitada para predecir la evolución clínica a 5 años, con un rendimiento cercano al azar y dificultades para identificar correctamente a los pacientes con mala evolución.

Tabla 36. Matriz de confusión para knn (K = 1)

Clase predicha / Clase real	Mala evolución	Buena evolución
Mala evolución	25 (TP)	37 (FP)
Buena evolución	49 (FN)	142 (TN)

Tabla 37. Métricas para knn (K = 1)

Tasa de acierto	Sensibilidad	Especificidad	Tasa de FP	Tasa de FN	Precisión	F1-score	AUROC	AUPRC
66,01 %	0,338	0,793	0,207	0,662	0,403	0,368	0,565	0,333

Tabla 38. Matriz de confusión para knn (K = 3)

Clase predicha / Clase real	Mala evolución	Buena evolución
Mala evolución	17 (TP)	19 (FP)
Buena evolución	57 (FN)	160 (TN)

Tabla 39. Métricas para knn (K = 3)

Tasa de acierto	Sensibilidad	Especificidad	Tasa de FP	Tasa de FN	Precisión	F1-score	AUROC	AUPRC
69,96 %	0,23	0,894	0,106	0,77	0,472	0,309	0,561	0,349

Tabla 40. Matriz de confusión para knn (K = 5)

Clase predicha / Clase real	Mala evolución	Buena evolución
Mala evolución	14 (TP)	13 (FP)
Buena evolución	60 (FN)	166 (TN)

Tabla 41. Métricas para knn (K = 5)

Tasa de acierto	Sensibilidad	Especificidad	Tasa de FP	Tasa de FN	Precisión	F1-score	AUROC	AUPRC
71,15 %	0,189	0,927	0,073	0,811	0,519	0,277	0,585	0,377

El modelo k-nearest neighbors con K=1 obtuvo una tasa de acierto del 66,01 %, clasificando correctamente 167 de las 253 muestras evaluadas. A partir de la matriz de confusión se observa que el modelo identificó correctamente 25 pacientes con mala evolución y 142 pacientes con buena evolución, cometiendo un total de 86 errores.

Considerando la clase mala evolución como clase positiva, la sensibilidad fue de 0,338, lo que indica que el modelo detectó correctamente 25 de los 74 pacientes con mala evolución. La especificidad fue de 0,793, por lo que reconoció correctamente 142 de los 179 pacientes con buena evolución. Estos resultados se corresponden con una tasa de falsos negativos de 0,662 y una tasa de falsos positivos de 0,207.

La precisión alcanzó un valor de 0,403, lo que indica que menos de la mitad de los pacientes clasificados como mala evolución pertenecían realmente a esa clase. La puntuación F1 fue de 0,368, mientras que los valores de AUROC y AUPRC fueron 0,565 y 0,333 respectivamente. Estos resultados muestran que, con K=1, el modelo presentó una capacidad limitada para anticipar la evolución clínica a 5 años.

El modelo k-nearest neighbors con K=3 obtuvo una tasa de acierto del 69,96 %, clasificando correctamente 177 de las 253 muestras evaluadas. A partir de la matriz de confusión se observa que el modelo identificó correctamente 17 pacientes con mala evolución y 160 pacientes con buena evolución, cometiendo un total de 76 errores.

Considerando la clase mala evolución como clase positiva, la sensibilidad fue de 0,23, lo que indica que el modelo detectó correctamente 17 de los 74 pacientes con mala evolución. La especificidad fue de 0,894, por lo que reconoció correctamente 160 de los 179 pacientes con buena evolución. Estos resultados se corresponden con una tasa de falsos negativos de 0,77 y una tasa de falsos positivos de 0,106.

La precisión alcanzó un valor de 0,472, lo que indica que algo menos de la mitad de los pacientes clasificados como mala evolución pertenecían realmente a esa clase. La puntuación F1 fue de 0,309, mientras que los valores de AUROC y AUPRC fueron 0,561 y 0,349 respectivamente. Aunque el modelo mejoró la tasa de acierto respecto a K=1, redujo la sensibilidad para la clase de mala evolución, por lo que dejó sin detectar a una parte importante de los pacientes con peor evolución.

El modelo k-nearest neighbors con K=5 obtuvo una tasa de acierto del 71,15 %, clasificando correctamente 180 de las 253 muestras evaluadas. A partir de la matriz de confusión se observa que el modelo identificó correctamente 14 pacientes con mala evolución y 166 pacientes con buena evolución, cometiendo un total de 73 errores.

Considerando la clase mala evolución como clase positiva, la sensibilidad fue de 0,189, lo que indica que el modelo detectó correctamente solo 14 de los 74 pacientes con mala evolución. La especificidad fue de 0,927, por lo que reconoció correctamente 166 de los 179 pacientes con buena evolución. Estos resultados se corresponden con una tasa de falsos negativos de 0,811 y una tasa de falsos positivos de 0,073.

La precisión alcanzó un valor de 0,519, lo que indica que aproximadamente la mitad de los pacientes clasificados como mala evolución pertenecían realmente a esa clase. La puntuación F1 fue de 0,277, mientras que los valores de AUROC y AUPRC fueron 0,585 y 0,377 respectivamente. Aunque K=5 obtuvo la mayor tasa de acierto entre las tres configuraciones, este resultado se debió principalmente a la correcta clasificación de pacientes con buena evolución, ya que la sensibilidad para detectar pacientes con mala evolución fue baja.

Tabla 42. Matriz de confusión para AdaBoostM1

Clase predicha / Clase real	Mala evolución	Buena evolución
Mala evolución	18 (TP)	33 (FP)
Buena evolución	56 (FN)	146 (TN)

Tabla 43. Métricas para AdaBoostM1

Tasa de acierto	Sensibilidad	Especificidad	Tasa de FP	Tasa de FN	Precisión	F1-score	AUROC	AUPRC
64,82 %	0,243	0,816	0,184	0,757	0,353	0,288	0,589	0,35

AdaBoostM1 obtuvo una tasa de acierto del 64,82 %, clasificando correctamente 164 de las 253 muestras evaluadas. A partir de la matriz de confusión se observa que el modelo identificó correctamente 18 pacientes con mala evolución y 146 pacientes con buena evolución, cometiendo un total de 89 errores.

Considerando la clase mala evolución como clase positiva, la sensibilidad fue de 0,243, lo que indica que el modelo detectó correctamente 18 de los 74 pacientes con mala evolución. La especificidad fue de 0,816, por lo que reconoció correctamente 146 de los 179 pacientes con buena evolución. Estos resultados se corresponden con una tasa de falsos negativos de 0,757 y una tasa de falsos positivos de 0,184.

La precisión alcanzó un valor de 0,353, lo que indica que una proporción reducida de los pacientes clasificados como mala evolución pertenecían realmente a esa clase. La puntuación F1 fue de 0,288, mientras que los valores de AUROC y AUPRC fueron 0,589 y 0,35 respectivamente. Estos resultados muestran que AdaBoostM1 presentó una capacidad limitada para anticipar la evolución clínica a 5 años, especialmente por su baja sensibilidad para detectar pacientes con mala evolución.

Tabla 44. Matriz de confusión para MLP

Clase predicha / Clase real	Mala evolución	Buena evolución
Mala evolución	28 (TP)	30 (FP)
Buena evolución	46 (FN)	149 (TN)

Tabla 45. Métricas para MLP

Tasa de acierto	Sensibilidad	Especificidad	Tasa de FP	Tasa de FN	Precisión	F1-score	AUROC	AUPRC
69,96 %	0,378	0,832	0,168	0,622	0,483	0,424	0,652	0,449

1 El modelo MLP obtuvo una tasa de acierto del 69,96 %, clasificando correctamente 177 de las 253 muestras evaluadas. A partir de la matriz de confusión se observa que el modelo identificó correctamente 28 pacientes con mala evolución y 149 pacientes con buena evolución, cometiendo un total de 76 errores.

3 Considerando la clase mala evolución como clase positiva, la sensibilidad fue de 0,378, lo que indica que el modelo detectó correctamente 28 de los 74 pacientes con mala evolución. La especificidad fue de 0,832, por lo que reconoció correctamente 149 de los 179 pacientes con buena evolución. Estos resultados se corresponden con una tasa de falsos negativos de 0,622 y una tasa de falsos positivos de 0,168.

11 La precisión alcanzó un valor de 0,483, lo que indica que cerca de la mitad de los pacientes clasificados como mala evolución pertenecían realmente a esa clase. La puntuación F1 fue de 0,424, mientras que los valores de AUROC y AUPRC fueron 0,652 y 0,449 respectivamente. Estos resultados muestran que el MLP obtuvo uno de los mejores comportamientos globales dentro de este experimento, aunque su capacidad para identificar pacientes con mala evolución siguió siendo limitada.

Tabla 46. Matriz de confusión para autoencoder

Clase predicha / Clase real	Mala evolución	Buena evolución
Mala evolución	6 (TP)	8 (FP)
Buena evolución	68 (FN)	171 (TN)

Tabla 47. Métricas para autoencoder

Tasa de acierto	Sensibilidad	Especificidad	Tasa de FP	Tasa de FN	Precisión	F1-score	AUROC	AUPRC
69,96 %	0,081	0,955	0,045	0,919	0,429	0,136	0,573	0,358

En este análisis se evaluó un enfoque basado en autoencoder idéntico al del primer experimento.

El modelo basado en autoencoder obtuvo una tasa de acierto del 69,96 %, clasificando correctamente 177 de las 253 muestras evaluadas. A partir de la matriz de confusión se observa que el modelo identificó correctamente 6 pacientes con mala evolución y 171 pacientes con buena evolución, cometiendo un total de 76 errores.

Considerando la clase mala evolución como clase positiva, la sensibilidad fue de 0,081, lo que indica que el modelo detectó correctamente solo 6 de los 74 pacientes con mala evolución. La especificidad fue de 0,955, por lo que reconoció correctamente 171 de los 179 pacientes con buena evolución. Estos resultados se corresponden con una tasa de falsos negativos de 0,919 y una tasa de falsos positivos de 0,045.

La precisión alcanzó un valor de 0,429, lo que indica que menos de la mitad de los pacientes clasificados como mala evolución pertenecían realmente a esa clase. La puntuación F1 fue de 0,136, mientras que los valores de AUROC y AUPRC fueron 0,573 y 0,358 respectivamente. Estos resultados muestran que, aunque el autoencoder permitió trabajar con una representación comprimida de los datos, en este experimento no mejoró la capacidad de predicción de la evolución clínica, especialmente debido a su baja sensibilidad para detectar pacientes con mala evolución.

3.4 Conclusiones

Los resultados obtenidos en la predicción tumoral muestran que los perfiles de metilación seleccionados contienen una señal clara para diferenciar entre muestras tumorales y normales. Los modelos alcanzaron un rendimiento elevado, lo que sugiere que las 1000 posiciones CpG seleccionadas capturan diferencias relevantes entre ambos tipos de tejido. Aunque existieron pequeñas diferencias entre modelos, el comportamiento general fue consistente. Estos obtuvieron métricas muy similares, a excepción de Naive Bayes, que necesitó discretización supervisada para obtener un rendimiento competitivo.

Además del rendimiento global, se analizaron las posiciones CpG más relevantes identificadas por algunos modelos. Entre ellas, destacó especialmente cg11717189, que apareció como una variable relevante tanto en la regresión logística como en la SVM, en ambos casos asociada a la clasificación de muestras tumorales. Esta coincidencia sugiere que dicha posición CpG podría tener una contribución importante en la separación entre muestras tumorales y normales dentro del conjunto analizado. No obstante, el resto de posiciones relevantes variaron entre modelos, lo que indica que cada clasificador pudo apoyarse en combinaciones diferentes de CpGs para realizar la clasificación.

Como comprobación adicional, se realizó una prueba utilizando el mismo conjunto de datos pero con las etiquetas de clase mezcladas aleatoriamente. El objetivo de esta prueba fue comprobar si los modelos seguían obteniendo un rendimiento elevado cuando se elimina la relación real entre los perfiles de metilación y la clase de cada muestra. En este escenario, se obtuvieron resultados próximos al azar, con tasas de acierto cercanas al 50 %. Estos resultados indican que, al romper la asociación entre los datos de metilación y la clase, los modelos dejaron de mostrar capacidad predictiva. Por tanto, esta comprobación sugiere que los resultados elevados obtenidos con las etiquetas reales no se deben a una fuga evidente de información, sino a la existencia de patrones de metilación relevantes para distinguir entre muestras tumorales y normales.

A pesar de los buenos resultados, estos deben interpretarse cuidadosamente. La evaluación se realizó sobre un conjunto de datos reducido y procedente de una única fuente. Por este motivo, los resultados deben entenderse como una evaluación interna del rendimiento y no como una validación definitiva de la capacidad de generalización de los modelos.

Los resultados de la predicción de evolución clínica a 5 años fueron claramente inferiores a los obtenidos en la clasificación entre muestras tumorales y normales. Aunque algunos modelos alcanzaron tasas de acierto

cercanas al 70 %, este valor debe interpretarse con cautela, ya que el conjunto estaba desbalanceado hacia la clase de buena evolución.

La mayoría de los modelos presentaron baja sensibilidad para la clase de mala evolución, lo que indica que tuvieron dificultades para identificar correctamente a los pacientes con peor pronóstico. MLP fue el modelo con mejor comportamiento global, al presentar el valor más alto de AUROC y una de las mejores puntuaciones F1 para la clase de mala evolución, aunque su rendimiento siguió siendo moderado. Otros modelos, como Random Forest o el enfoque con autoencoder, mostraron una especificidad elevada pero una sensibilidad muy baja, debido a que tendieron a clasificar la mayoría de los casos como buena evolución.

Estos resultados sugieren que la predicción de evolución clínica a partir de perfiles de metilación es una tarea más compleja que la diferenciación entre tejido tumoral y tejido normal. Para obtener modelos pronósticos más robustos sería necesario disponer de más pacientes con seguimiento clínico suficiente, incorporar variables clínicas adicionales y utilizar enfoques más específicos.

6

En definitiva, los resultados muestran que los perfiles de metilación del ADN contienen información relevante para diferenciar entre muestras tumorales y normales en cáncer de mama, obteniéndose un rendimiento elevado. Por otro lado, el análisis exploratorio de evolución clínica presentó resultados más moderados, mostrando que la predicción pronóstica constituye una tarea más compleja que la clasificación tumoral. En conjunto, este trabajo confirma el interés de las técnicas de inteligencia artificial para analizar perfiles de metilación y estudiar su relación con distintos aspectos del cáncer, desde la diferenciación entre tejido tumoral y normal hasta una primera aproximación a la evolución clínica de los pacientes.

15

4 Análisis de Impacto

Este trabajo tiene un impacto principalmente académico y formativo. A nivel personal, me ha permitido aplicar conocimientos de inteligencia artificial, análisis de datos y biología molecular sobre un problema real relacionado con el cáncer de mama. Durante el desarrollo del TFG se han trabajado aspectos como la preparación de datos, la comparación de modelos y la interpretación de resultados, lo que ha ayudado a comprender mejor tanto las posibilidades como las limitaciones de aplicar inteligencia artificial en el ámbito biomédico.

Desde el punto de vista social, el trabajo se relaciona con el estudio del cáncer de mama, una enfermedad con gran impacto en la población. Los resultados muestran que los perfiles de metilación del ADN pueden contener información útil para diferenciar entre muestras tumorales y normales. Además, el análisis de evolución clínica permitió observar que predecir la evolución de los pacientes es una tarea más compleja, por lo que los resultados deben interpretarse con prudencia y no como una herramienta clínica definitiva.

En el ámbito empresarial y económico, este tipo de análisis puede ser útil para áreas como la bioinformática y la investigación biomédica, ya que permite estudiar grandes conjuntos de datos y seleccionar información potencialmente relevante. Sin embargo, los modelos obtenidos en este trabajo no están pensados para utilizarse directamente en hospitales o empresas, sino como una primera aproximación experimental que necesitaría más validación antes de cualquier aplicación práctica.

El impacto medioambiental del trabajo es reducido, ya que se han utilizado datos públicos ya existentes y no se han generado nuevas muestras ni experimentos de laboratorio. Además, se redujo el número de variables analizadas, lo que permitió realizar los experimentos con un menor coste computacional.

Desde el punto de vista ético, es importante destacar que los datos genómicos y epigenéticos son información sensible, aunque en este trabajo se hayan utilizado datos públicos y anonimizados. Por ello, los resultados se han tratado con cautela, evitando presentarlos como diagnósticos o predicciones clínicas definitivas.

Este trabajo se vincula principalmente con el Objetivo de Desarrollo Sostenible 3: salud y bienestar, ya que aborda un problema relacionado con el estudio del cáncer. Asimismo, se relaciona con el Objetivo de Desarrollo Sostenible 9: industria, innovación e infraestructura, por el uso de técnicas de inteligencia artificial aplicadas al análisis de datos biomédicos.

5 Bibliografía

- [1] L. D. Moore, T. Le, and G. Fan, "DNA methylation and its basic function," *Neuropsychopharmacology*, vol. 38, no. 1, pp. 23–38, 2013, doi: 10.1038/npp.2012.112.
- [2] C. M. Lanata, S. A. Chung, and L. A. Criswell, "DNA methylation 101: what is important to know about DNA methylation and its role in SLE risk and disease heterogeneity," *Lupus Science & Medicine*, vol. 5, no. 1, p. e000285, 2018, doi: 10.1136/lupus-2018-000285.
- [3] A. O. Adetunji, H. Owusu, E. F. Adewale, P. A. Adesina, C. Xedzro, T. P. Saliu, S. Islam, Z. Zhu, and O. B. Morenikeji, "DNA methylation: A key regulator in male and female reproductive outcomes," *Life*, vol. 15, no. 7, p. 1109, 2025, doi: 10.3390/life15071109.
- [4] R. Gabbianelli, "Impact of social stress on epigenetics: an updated narrative review," *Journal of Laboratory and Precision Medicine*, vol. 10, p. 14, 2025, doi: 10.21037/jlpm-25-4.
- [5] M. Tahiliani et al., "Conversion of 5-methylcytosine to 5-hydroxymethylcytosine in mammalian DNA by MLL partner TET1," *Science*, vol. 324, no. 5929, pp. 930–935, 2009, doi: 10.1126/science.1170116.
- [6] B. Jin, Y. Li, and K. D. Robertson, "DNA methylation: superior or subordinate in the epigenetic hierarchy?," *Genes & Cancer*, vol. 2, no. 6, pp. 607–617, 2011, doi: 10.1177/1947601910393957.
- [7] R. Lakshminarasimhan and G. Liang, "The role of DNA methylation in cancer," *Advances in Experimental Medicine and Biology*, vol. 945, pp. 151–172, 2016, doi: 10.1007/978-3-319-43624-1_7.
- [8] E. Zarean, S. Li, M. C. Southey, and P.-A. Dugué, "A review of the use of tumour DNA methylation for breast cancer subtyping and prediction of outcomes," *Clinical Epigenetics*, vol. 17, p. 109, 2025, doi: 10.1186/s13148-025-01922-z.
- [9] T. Witte, C. Plass, and C. Gerhauser, "Pan-cancer patterns of DNA methylation," *Genome Medicine*, vol. 6, p. 66, 2014, doi: 10.1186/s13073-014-0066-6.
- [10] R. Pidsley et al., "Critical evaluation of the Illumina MethylationEPIC BeadChip microarray for whole-genome DNA methylation profiling," *Genome Biology*, vol. 17, p. 208, 2016, doi: 10.1186/s13059-016-1066-1.
- [11] P. Du et al., "Comparison of Beta-value and M-value methods for quantifying methylation levels by microarray analysis," *BMC Bioinformatics*, vol. 11, p. 587, 2010, doi: 10.1186/1471-2105-11-587.

[12] M. J. Aryee et al., “Minfi: a flexible and comprehensive Bioconductor package for the analysis of Infinium DNA methylation microarrays,” *Bioinformatics*, vol. 30, no. 10, pp. 1363–1369, 2014, doi: 10.1093/bioinformatics/btu049.

[13] J. Wang, “ComBat-met: adjusting batch effects in DNA methylation data,” *NAR Genomics and Bioinformatics*, vol. 7, no. 2, p. lqaf062, 2025, doi: 10.1093/nargab/lqaf062.

[14] R. Gomes, N. Paul, N. He, A. F. Huber, and R. J. Jansen, “Application of feature selection and deep learning for cancer prediction using DNA methylation markers,” *Genes*, vol. 13, no. 9, p. 1557, 2022, doi: 10.3390/genes13091557.

[15] T. Doherty et al., “A comparison of feature selection methodologies and learning algorithms in the development of a DNA methylation-based telomere length estimator,” *BMC Bioinformatics*, vol. 24, p. 178, 2023, doi: 10.1186/s12859-023-05282-4.

[16] B. Ma et al., “Diagnostic classification of cancers using DNA methylation of paracancerous tissues,” *Scientific Reports*, vol. 12, p. 10646, 2022, doi: 10.1038/s41598-022-14786-7.

[17] K. Sahoo et al., “Artificial Intelligence in cancer epigenomics: a review on advances in pan-cancer detection and precision medicine,” *Epigenetics & Chromatin*, vol. 18, p. 35, 2025, doi: 10.1186/s13072-025-00595-5.

[18] M. Yassi, A. Chatterjee, and M. Parry, “Application of deep learning in cancer epigenetics through DNA methylation analysis,” *Briefings in Bioinformatics*, vol. 24, no. 6, p. bbad411, 2023, doi: 10.1093/bib/bbad411.

[19] J. J. Levy et al., “MethylNet: an automated and modular deep learning approach for DNA methylation analysis,” *BMC Bioinformatics*, vol. 21, p. 108, 2020, doi: 10.1186/s12859-020-3443-8.

[20] S. Chatterjee, A. Iyer, S. Avva, A. Kollara, and M. Sankarasubbu, “Convolutional Neural Networks in classifying cancer through DNA methylation,” *arXiv:1807.09617*, 2018. [Online]. Available: <https://arxiv.org/abs/1807.09617>

[21] L. Tong, J. Mitchel, K. Chatlin, and M. D. Wang, “Deep learning based feature-level integration of multi-omics data for breast cancer patients survival analysis,” *BMC Medical Informatics and Decision Making*, vol. 20, p. 225, 2020, doi: 10.1186/s12911-020-01225-8.

[22] S. A. Hicks et al., “On evaluation metrics for medical applications of artificial intelligence,” *Scientific Reports*, vol. 12, p. 5979, 2022, doi: 10.1038/s41598-022-09954-8.

[23] D. Berrar, “Cross-validation,” in *Encyclopedia of Bioinformatics and Computational Biology*, 2nd ed., vol. 1, London, UK: Elsevier, 2025, pp. 638–644, doi: 10.1016/B978-0-323-95502-7.00032-4.

[24] E. Aref-Eshghi et al., “DNA methylation and machine learning: challenges and perspective toward enhanced clinical diagnostics,” *Clinical Epigenetics*, vol. 17, 2025, doi: 10.1186/s13148-025-01967-0.

[25] S. M. Lundberg and S.-I. Lee, “A unified approach to interpreting model predictions,” in *Advances in Neural Information Processing Systems* 30, 2017, pp. 4765–4774. [Online]. Available: <https://arxiv.org/abs/1705.07874>

[26] National Cancer Institute, “The Cancer Genome Atlas Program (TCGA).” [Online]. Available: <https://www.cancer.gov/ccg/research/genome-sequencing/tcga>. Accessed: Jul. 6, 2026.

[27] University of Waikato, “ARFF stable,” Weka Wiki. [Online]. Available: https://waikato.github.io/weka-wiki/formats_and_processing/arff_stable/. Accessed: Jul. 6, 2026.

[28] E. Frank, M. A. Hall, and I. H. Witten, “The WEKA Workbench. Online Appendix for Data Mining: Practical Machine Learning Tools and Techniques,” 4th ed., Morgan Kaufmann, 2016. [Online]. Available: https://ml.cms.waikato.ac.nz/weka/Witten_et_al_2016_appendix.pdf

6 Anexos

Este capítulo es opcional, y se escribirá de acuerdo con las indicaciones del Tutor.